Clasificación automática de 104 tipos de flores con redes neuronales profundas*

Angel Eduardo-Luna[a,1], Andrea Estefanía De la Peña Contreras[a,2], Jannette Cristina Flores Rodríguez[a,3], Rey Iván de la Fuente Chávez[a,4] and Andrés Huerta Robinson[a,5]

[a]*Escuela de Ingeniería y Ciencias, Tecnológico de Monterrey, Monterrey, Nuevo León, México*

INFORMACIÓN

Palabras clave:
Clasificación de imágenes
CNN
MLP
Regularización
F1 macro

Resumen

Se estudia la clasificación de 104 categorías de flores mediante una MLP sobre píxeles aplanados y CNN entrenadas desde cero con entrada RGB de 112×112. Se analizan cuatro corridas históricas A4 sobre 12,753 imágenes de entrenamiento y 3,712 de validación. La CNN original obtiene F1 macro 0.5740 y exactitud 63.25 %, frente a 0.0280 y 15.52 % de la MLP; una CNN de seis convoluciones obtiene 0.5502 y 62.23 %. Se selecciona la CNN de cuatro convoluciones con AdamW y tasa adaptable por F1 macro 0.5745, exactitud 64.44 % y checkpoint 61 de 73 épocas. Como evidencia complementaria separada, dos corridas TensorFlow del reporte final permiten comparar la regularización conjunta: F1 macro 0.5784 con dropout, aumentos y AdamW, frente a 0.5332 sin esas intervenciones; la brecha F1 de entrenamiento limpio menos validación baja de 0.3435 a 0.2354. En la época común 34 la variante sin regularización tiene mayor F1, aunque mayor pérdida y brecha. Se incluyen curvas, métricas de las 104 clases y matriz de confusión. Los resultados provienen de una semilla y de validación usada para selección; no constituyen una prueba independiente ni una atribución causal individual.

1. Resumen y objetivos

El objetivo es evaluar modelos de clasificación multiclase de flores y estudiar su capacidad de ajuste y generalización. Se comparan una red totalmente conectada (MLP), una CNN de cuatro convoluciones, una variante de seis convoluciones y una CNN con AdamW y ajuste de tasa. Se cuantifican F1 macro, exactitud, pérdida, parámetros y errores por clase. La MLP es una referencia reconstruida con el pipeline del equipo; no se atribuye a un checkpoint MLP del Avance 3.

Para estudiar la regularización se incorpora, en un grupo experimental separado, un par de corridas existentes con y sin dropout, aumento de datos y decaimiento de pesos. Se presentan tanto sus mejores checkpoints como una comparación en la misma época registrada. Las curvas y las brechas permiten distinguir mayor ajuste de train de una mejora efectiva en validación.

2. Contexto del problema

Reconocer flores en fotografías requiere distinguir categorías con colores, texturas y formas semejantes bajo variaciones de pose, escala, fondo e iluminación. El problema se plantea como clasificación supervisada: dada una imagen RGB, se predice una de 104 etiquetas de la competencia *Petals to the Metal* (Kaggle, s.f.). La variación dentro de cada clase y el desbalance hacen necesario evaluar algo más que el porcentaje global de aciertos.

Un clasificador de este tipo puede apoyar identificación educativa, organización de colecciones y revisión de observaciones de biodiversidad. Su alcance se restringe a las categorías disponibles: no identifica cualquier especie ni reconoce de forma confiable clases ajenas al entrenamiento. Los resultados de validación tampoco sustituyen una evaluación en fotografías de otro dominio.

Tabla 1
Particiones originales utilizadas.

Partición	Imágenes	Etiquetas locales
Train	12,753	Sí
Validación	3,712	Sí
Test	7,382	No
Total	23,847	

3. Descripción del dataset

3.1. Datos y particiones

Se utilizan los TFRecords de la competencia *Petals to the Metal – Flower Classification on TPU* (Kaggle, s.f.), con 104 clases y fotografías RGB. El conjunto incluye categorías relacionadas con la clasificación fina de flores, estudiada también en Oxford Flowers (Nilsback and Zisserman, 2008). Se mantienen las particiones originales de Kaggle (Tabla 1). Cada registro etiquetado contiene una imagen JPEG y una clase entera de 0 a 103; test proporciona identificadores para generar predicciones. Se leen los archivos de origen de 224×224, pero la entrada efectiva de todos los modelos analizados es $112 \times 112 \times 3$. No se crea una partición nueva ni se usan imágenes de validación para actualizar pesos.

* Situación problema: Red convolutiva, Avance 4. Diseño de Redes Neuronales y Aprendizaje Profundo (TC2035.201). Basado en la competencia *Petals to the Metal – Flower Classification on TPU* (Kaggle).

[1] Matrícula: A00842657
[2] Matrícula: A00840973
[3] Matrícula: A01255711
[4] Matrícula: A01709445
[5] Matrícula: A00838626

3.2. Desbalance y métricas

El conteo histórico de train varía entre 18 y 782 imágenes por clase; su promedio es 122.6. La exactitud global puede favorecer clases numerosas. Por ello el criterio principal es F1 macro, que pondera por igual las 104 categorías. Para una clase c, con verdaderos positivos TP_c, falsos positivos FP_c y falsos negativos FN_c:

$$P_c = \frac{TP_c}{TP_c + FP_c}, \qquad R_c = \frac{TP_c}{TP_c + FN_c}, \tag{1}$$

$$F1_c = \frac{2P_cR_c}{P_c + R_c}, \qquad F1_{\text{macro}} = \frac{1}{104}\sum_{c=0}^{103} F1_c. \tag{2}$$

Los denominadores nulos se resuelven asignando cero a la métrica. El soporte es el número de imágenes reales de esa clase en validación. Se informa también exactitud y entropía cruzada: esta última penaliza errores de alta confianza que un cambio de clase predicha no refleja por sí solo.

4. Algoritmos y aplicaciones

4.1. Red totalmente conectada

La MLP transforma la imagen en un vector $x \in \mathbb{R}^{37,632}$ y aplica $h = \text{ReLU}(Wx + b)$, dropout y una capa lineal de 104 salidas. Cada neurona recibe todos los píxeles con pesos independientes por posición. Esta conectividad permite relaciones globales, pero no incorpora explícitamente la vecindad espacial ni reutiliza un detector entre regiones. La primera matriz de 37,632 por 256 domina el costo en parámetros.

4.2. Convolución, activación y pooling

Una CNN aplica el mismo kernel a vecindarios de la imagen. De forma esquemática, un mapa de salida es

$$a_{i,j,k} = \text{ReLU}\left(b_k + \sum_{u,v,c} K_{u,v,c,k}\, x_{i+u,j+v,c}\right). \tag{3}$$

La conectividad local conserva relaciones entre píxeles cercanos y los filtros compartidos reducen parámetros respecto a conectar cada píxel con cada unidad. La composición de capas permite combinar patrones locales en representaciones más complejas. El max pooling de 2×2 reduce tamaño espacial y aporta cierta tolerancia a desplazamientos, sin garantizar invariancia completa. Global average pooling (GAP) promedia cada mapa y evita una gran matriz densa sobre todas las posiciones. Estas propiedades motivan las CNN para imágenes (Clark, 2025); su ventaja concreta se evalúa empíricamente.

4.3. Aprendizaje y regularización

Los modelos producen logits, no una segunda softmax antes de la pérdida. Para la etiqueta verdadera c se minimiza entropía cruzada dispersa:

$$L = -\log \frac{\exp(z_c)}{\sum_{k=0}^{103} \exp(z_k)}. \tag{4}$$

La retropropagación calcula gradientes y Adam actualiza pesos por minilotes. Dropout desactiva unidades aleatorias durante entrenamiento; los aumentos presentan variaciones de imágenes reales. AdamW aplica decaimiento de pesos desacoplado del gradiente de la pérdida. La reducción de tasa en meseta y la parada temprana controlan el progreso y la selección del checkpoint. Sus efectos no pueden aislarse cuando varias condiciones cambian simultáneamente.

4.4. Alternativas y alcance

KNN, SVM y bosques aleatorios sobre características, así como arquitecturas preentrenadas, son alternativas posibles; no se presentan como modelos ejecutados en esta comparación. La aplicación considerada exige clasificar las 104 etiquetas del dataset, con cautela ante cambios de dominio y clases no conocidas.

5. Metodología

5.1. Arquitecturas entrenadas

La MLP aplica Flatten, Dense256/ReLU, dropout 0.5 y Dense104; tiene 9,660,776 parámetros. La primera capa aporta 9,634,048 (99.72 %), porque cada uno de los 37,632 valores de entrada se conecta con las 256 unidades, además de sus sesgos. No contiene convoluciones ni pooling.

La CNN original contiene cuatro Conv 3×3, padding *same*, con 32, 64, 128 y 256 filtros, ReLU y max pooling 2×2 por bloque. Las salidas son $56 \times 56 \times 32$, $28 \times 28 \times 64$, $14 \times 14 \times 128$ y $7 \times 7 \times 256$. GAP, Dense256/ReLU, dropout 0.5 y Dense104 completan 480,936 parámetros. La CNN ampliada añade Conv128 después de pool3 y Conv256 después de pool4, ambas 3×3/ReLU, sin pool adicional: seis convoluciones y 1,218,600 parámetros. La variante AdamW/LR conserva la arquitectura original.

5.2. Preprocesamiento

El lector decodifica JPEG RGB, convierte a float32, divide por 255 y redimensiona con interpolación bilineal y antialias a 112×112. Train se mezcla y usa volteo horizontal, rotación de factor 0.05, zoom 0.1 y contraste 0.1; los valores se recortan a $[0, 1]$. La caché precede a los aumentos, que cambian entre épocas. Validación no usa transformaciones aleatorias. La MLP aplana en orden NHWC, coherente entre su implementación PyTorch y la exportación Keras.

5.3. Implementación y procedencia

Las cuatro corridas A4 se entrenaron históricamente con PyTorch/DirectML en Radeon RX 6700S y lector TensorFlow; sus checkpoints PT se exportaron a Keras. Los registros conservan una prueba histórica de paridad sobre un lote. Este análisis recalcula métricas desde las predicciones guardadas y coteja las pérdidas con los archivos; no vuelve a ejecutar inferencia sobre imágenes.

El par complementario F procede del reporte final y utiliza TensorFlow/Metal, según su documentación. No se trata de una repetición DirectML. La destilación Distribution Matching pertenece a otro experimento del proyecto: no se

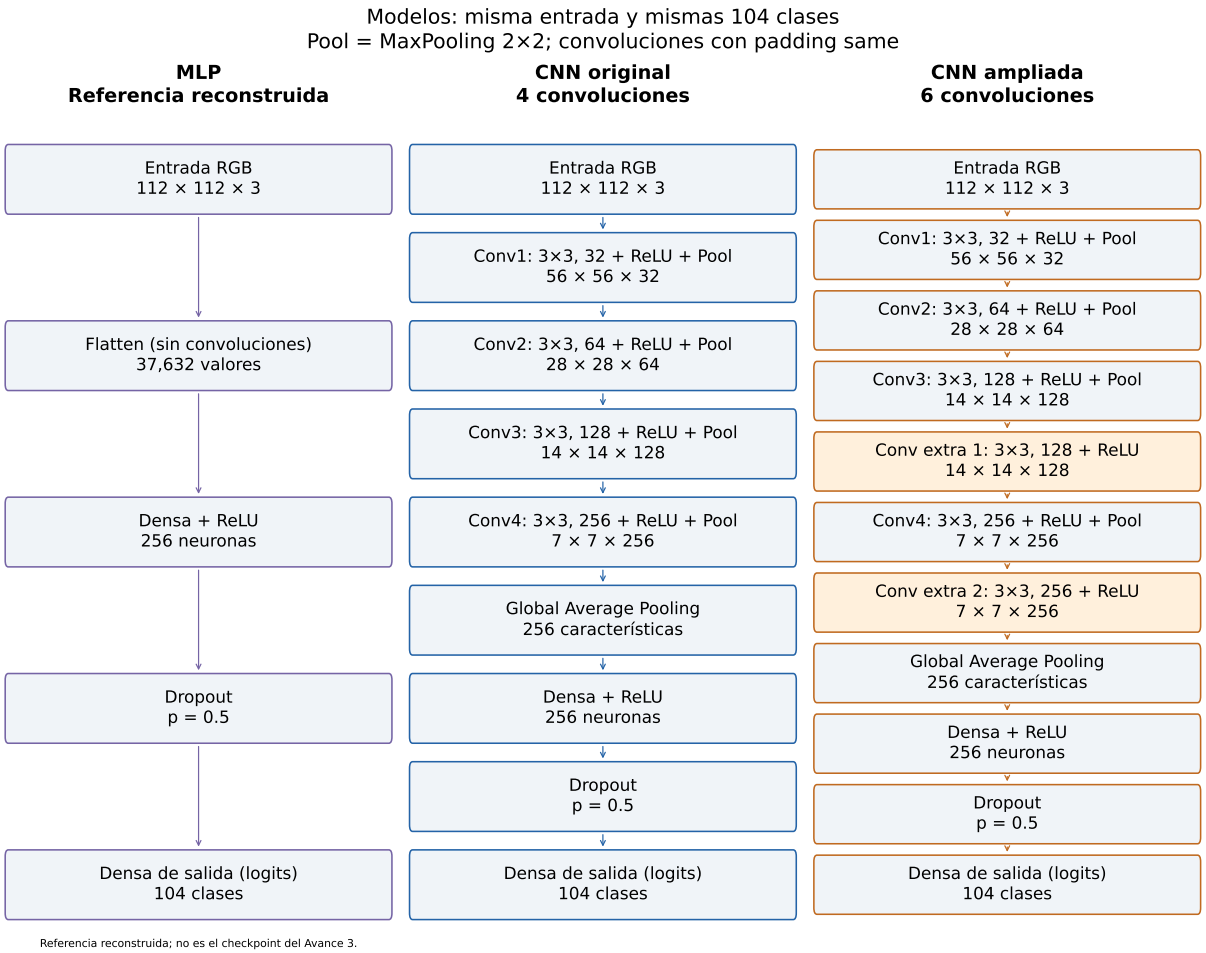


Figura 1: Arquitecturas históricas A4 con entrada efectiva de 112 por 112. Las capas adicionales de la CNN ampliada se muestran en naranja.

usaron sus imágenes sintéticas para entrenar las seis corridas aquí comparadas.

6. Protocolo experimental y reproducibilidad

6.1. Familias y condiciones

Se distinguen **A4**: MLP, CNN original, CNN ampliada y CNN AdamW/LR; y **F**: CNN con y sin intervención conjunta de regularización del reporte final. Todas declaran seed 0, train completo, la misma validación, entrada 112, batch 64 y hasta 150 épocas. No se promedian resultados entre familias.

En A4, las CNN original y ampliada usan Adam LR 10^{-3} y paciencia de cinco evaluaciones sin mejora de F1. La MLP usa Adam LR 10^{-4}, paciencia diez y mínimo diez épocas, después de un ensayo fallido con 10^{-3}. La CNN AdamW/LR usa weight decay 0.01 sin sesgos, reducción por pérdida de validación de factor 0.5, paciencia dos, mínimo 10^{-5} y parada temprana de doce evaluaciones. Todos los A4 usan dropout 0.5 y aumentos: su comparación Adam/AdamW no equivale a retirar toda la regularización explícita.

En F se compara dropout 0.5, aumentos y AdamW/WD 0.01 frente a dropout 0, sin aumentos y Adam/WD 0. Ambas conservan LR inicial 10^{-3}, la misma regla de reducción de tasa, paciencia doce y tope 150. Sus trayectorias reales de LR pueden diferir. El checkpoint se selecciona por máximo F1 macro; exactitud y pérdida se asocian a ese mismo modelo, no a máximos independientes.

6.2. Medición de la brecha

En A4, train se mide durante actualizaciones con dropout y aumentos. En F se registran además las primeras 3,712 imágenes fijas de train, sin aumentos y en modo inferencia al final de cada época. Solo estas métricas limpias permiten comparar con validación bajo el mismo modo de evaluación:

$$\Delta F = F1_{\text{train,limpio}} - F1_{\text{val}}. \tag{5}$$

Ese subconjunto no es todo train ni una muestra estratificada. Sus métricas se recuperan de históricos, sin predicciones individuales de train para repetir el recálculo. Se comparan mejores checkpoints y, como complemento, la época 34 registrada en ambas corridas F. No se interpolan valores ausentes.

Tabla 2
Familia F: mejores checkpoints por F1 macro, con y sin intervención conjunta.

Variante	Época	F_t	F_v	E_t(%)	E_v(%)	L_t	L_v	ΔF
Con	91	0.8138	0.5784	83.00	64.06	0.5571	1.4830	0.2354
Sin	34	0.8767	0.5332	87.34	59.64	0.4434	2.0395	0.3435

t: 3,712 imágenes fijas de train, sin aumentos y en inferencia; v: 3,712 de validación. F: F1 macro; E: exactitud; L: entropía cruzada; $\Delta F = F_t - F_v$. TensorFlow/Metal según documentación histórica; train y pérdidas solo cotejados con históricos.

6.3. Artefactos y límites de ejecución

Los originales A4 están en `reports/entregable_4/avance4_2026-10-21`; el par F, en `reports/final/experimentos/runs`. Los derivados registran IDs de familia, rutas y hashes en carpetas de corrección del A4. La tabla completa por clase se obtiene de predicciones, sin modificar sus fuentes.

El notebook `notebooks/equipo_proyecto_avance4.ipynb` del repositorio del equipo separa análisis histórico de entrenamiento. El primer modo usa CSV/JSON sin frameworks de entrenamiento ni TFRecords; el segundo exige datos y dependencias y escribe en una salida nueva. En el entorno de revisión faltaron TFRecords y frameworks, por lo que no se reentrenaron modelos ni se recalcularon pérdidas sobre imágenes. Una semilla no estima variabilidad; validación también se usa para seleccionar modelos y no constituye test independiente.

7. Regularización y generalización

7.1. Evidencia complementaria F

La Tabla 2 compara los checkpoints F con mayor F1 macro: época 91 de 103 con regularización conjunta y 34 de 46 sin ella. La versión regularizada obtiene F1 0.5784 y exactitud 64.06 %, frente a 0.5332 y 59.64 %. La diferencia es +0.045155 de F1 y +4.4181 puntos porcentuales de exactitud. La brecha F1 baja de 0.3435 a 0.2354, una reducción de 0.108023.

Sin dropout, aumentos ni decaimiento, F1 de train limpio alcanza 0.8767, superior a 0.8138 de la referencia, pero val obtiene menor F1 y mayor pérdida (2.0395 frente a 1.4830). Este patrón es compatible con mayor sobreajuste: ajustar mejor ejemplos conocidos no garantiza mejores predicciones fuera de train. La pérdida de validación puede crecer aunque F1 cambie poco, por errores incorrectos más confiados. Las curvas completas se muestran en Figura 2.

7.2. Comparación en la época común 34

Los dos historiales contienen todas las métricas en las épocas 1–46. La Tabla 3 extrae la fila exacta de la época 34. Sin regularización, F1 val 0.5332 y exactitud 59.64 % superan a 0.4851 y 56.98 % de la regularizada en ese punto. Sin embargo, la regularizada tiene menor loss val (1.6289 frente a 2.0395) y menor brecha F1 (0.0942 frente a 0.3435).

Por tanto, no hay dominio de la variante regularizada en todas las épocas. Ajusta más lentamente y sigue mejorando después; su checkpoint seleccionado alcanza mejor F1 que el máximo de la variante sin esas intervenciones. Una brecha pequeña temprana puede reflejar ajuste insuficiente, por lo que se interpreta junto con métricas de ambos splits, no como sinónimo de mejor modelo.

7.3. Alcance de la intervención

Se modifican simultáneamente dropout, aumento, decaimiento de pesos y optimizador. No se puede cuantificar el aporte individual de cada técnica. Ambas corridas siguen usando parada temprana y ajuste de tasa; “sin regularización” denota la retirada de esas tres intervenciones explícitas. En época 34 las LR registradas son 10^{-3} con regularización y 1.25×10^{-4} sin ella: el punto común no es un ensayo causal completamente controlado. Los resultados de una semilla no permiten afirmar significancia estadística ni una mejora universal. Las brechas de esta sección pertenecen únicamente a F, no a las corridas A4.

8. Resultados, análisis y conclusiones

8.1. Comparación de las cuatro corridas A4

La Tabla 4 usa predicciones históricas sobre 3,712 imágenes y épocas de sus resúmenes/históricos. La MLP es una referencia reconstruida, no el modelo original de una entrega anterior. La CNN original supera a la MLP en 47.7371 puntos porcentuales de exactitud y 0.545941 de F1, con unas veinte veces menos parámetros. Conectividad local, filtros compartidos y pooling constituyen una explicación inductiva plausible; LR, paciencia y capacidades distintas impiden aislar un efecto puramente arquitectónico.

8.2. Ajuste de la MLP

La MLP A4 predice 21 de 104 clases y concentra 85.24 % de sus predicciones en cinco; 87 clases tienen F1 cero, incluidas cuatro que sí llega a predecir sin acertar. En checkpoint 77 su exactitud de train online es 12.06 %, con loss 3.6163; val obtiene 15.52 %, F1 0.0280 y loss 3.4032. Sus curvas (Figura 4) sugieren ajuste insuficiente, no memorización intensa. La mayor exactitud de val no prueba fuga: train incluye dropout y aumentos. No hay F1 limpio de train para esa corrida A4.

El ensayo previo con LR 10^{-3} colapsó según su registro; bajar a 10^{-4} mejoró, pero no resolvió el ajuste. La inspección estática encontró pesos finitos y sumas de pesos de entrada negativas en muchas unidades; esto motiva revisar centrado y activaciones, pero no demuestra neuronas ReLU muertas con imágenes reales. No se midieron de nuevo activaciones ni gradientes. Se conservaron los ensayos fallido e interrumpido por separado, sin sumar sus épocas a la corrida final. No

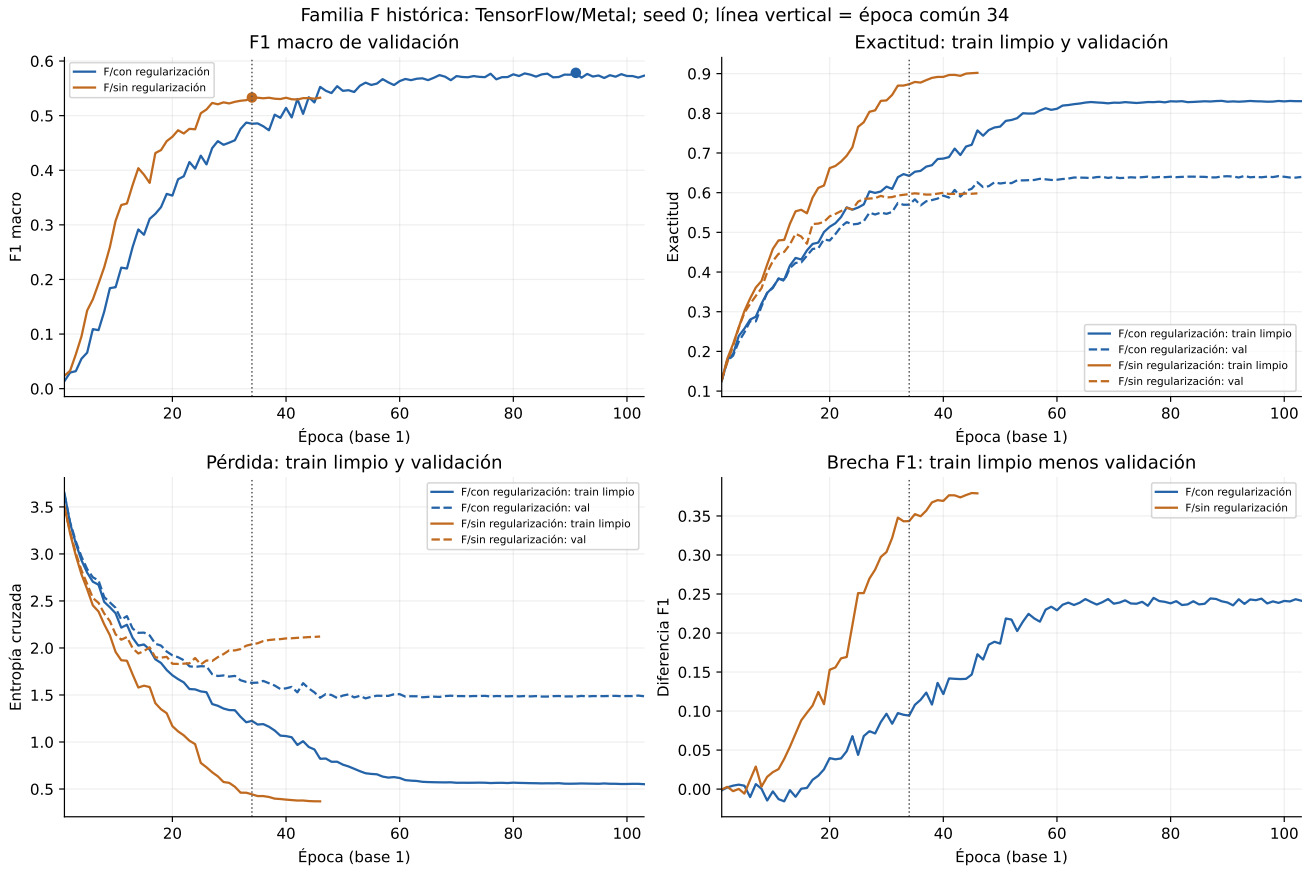


Figura 2: Familia F: curvas históricas y brecha F1. Train limpio usa 3,712 imágenes fijas sin aumentos ni dropout. Los puntos marcan checkpoints seleccionados; la línea vertical indica época 34.

Tabla 3
Familia F: comparación complementaria en la época 34 de ambas corridas.

Variante	Época	F_t	F_v	E_t(%)	E_v(%)	L_t	L_v	ΔF
Con	34	0.5793	0.4851	64.22	56.98	1.2247	1.6289	0.0942
Sin	34	0.8767	0.5332	87.34	59.64	0.4434	2.0395	0.3435

t: 3,712 imágenes fijas de train, sin aumentos y en inferencia; v: 3,712 de validación. F: F1 macro; E: exactitud; L: entropía cruzada; $\Delta F = F_t - F_v$. TensorFlow/Metal según documentación histórica; train y pérdidas solo cotejados con históricos.

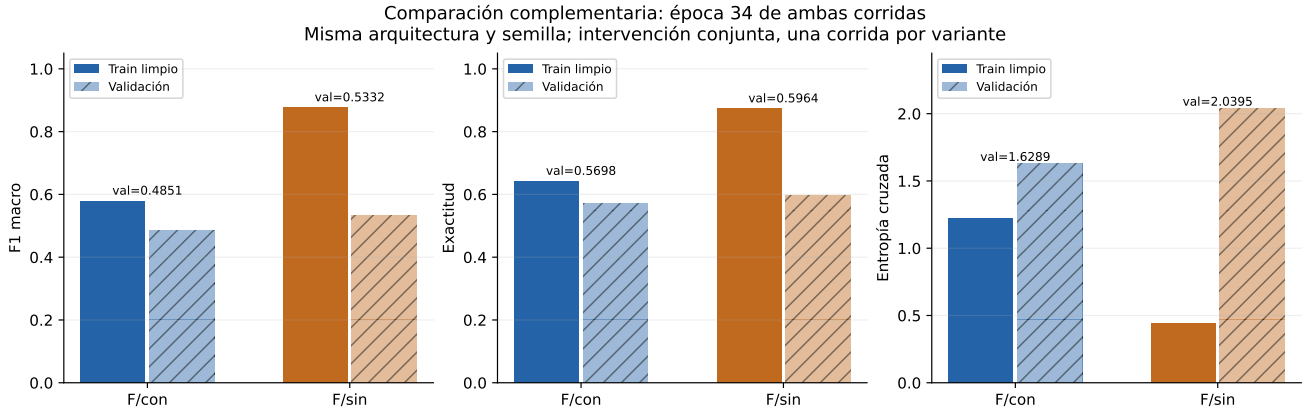


Figura 3: Métricas F en época 34. Las barras sólidas representan train limpio; las rayadas, validación. La misma época no implica igual trayectoria de optimización.

Tabla 4
Familia A4: validación histórica recalculada desde predicciones (3,712 imágenes).

Modelo	Parámetros	Época/total	Exact. (%)	F1 macro	Pérdida
MLP	9,660,776	77/87	15.52	0.0280	3.4032
CNN original	480,936	53/58	63.25	0.5740	1.5196
CNN ampliada	1,218,600	46/51	62.23	0.5502	1.7857
CNN AdamW/LR	480,936	61/73	64.44	0.5745	1.5075

Época seleccionada por F1 macro / épocas completas. PyTorch/DirectML, seed 0, entrada 112 por 112. La pérdida procede de evaluación guardada; no se repitió inferencia.

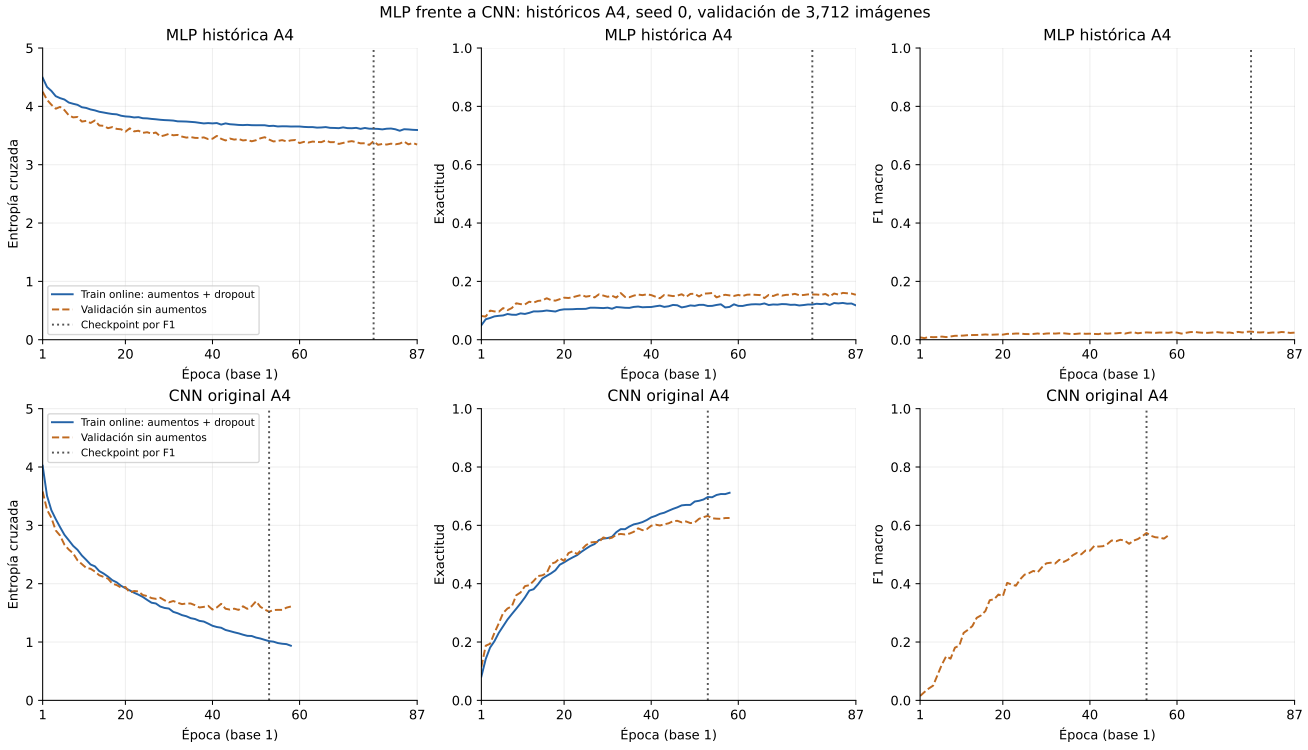


Figura 4: MLP y CNN original A4. Las escalas son comunes por métrica; train es online con aumentos/dropout. Cada línea punteada marca el checkpoint por F1.

se concluye que una MLP sea incapaz de aprender imágenes; requiere más diagnóstico de optimización y una política adecuada antes de usarla como referencia de rendimiento óptimo. La falta de datos/frameworks impidió probar una variante nueva y se conserva el baseline histórico con esta limitación.

8.3. Por qué la CNN ampliada no mejoró

Con seis convoluciones F1 baja de 0.5740 a 0.5502 y exactitud de 63.25 % a 62.23 %, mientras parámetros pasan de 480,936 a 1,218,600. La pérdida de val alcanza su mínimo 1.6582 en época 31 y termina en 2.0241; train termina en 0.5640 y exactitud 82.66 %. La CNN original termina con loss train 0.9365 y val 1.6085. La mayor separación y deterioro de val son compatibles con mayor sobreajuste de la ampliada en esta configuración. Más capacidad, optimización y regularización no adaptada son hipótesis; no se demuestra que toda red más profunda rinda peor ni que la resolución sea la causa única.

8.4. Modelo seleccionado y errores por clase

Se selecciona **A4-CNN-AdamW/LR** dentro de las cuatro corridas A4 por F1 macro 0.574474, exactitud 64.4397 % (2,392 aciertos de 3,712) y checkpoint 61 de 73. Su precisión macro es 0.621468 y recall macro 0.563465. La pérdida guardada es 1.507477. La diferencia de F1 respecto a la original es pequeña (0.000521); con una semilla no constituye mejora estadísticamente demostrada. La referencia F de la sección 7 no reemplaza a este modelo ni aporta sus métricas.

Las métricas de precisión, recall, F1 y soporte se recalculan para las 104 clases y se presentan completas en el anexo. La matriz normalizada tiene recall en la diagonal; su submatriz legible de errores se muestra en Figura 6. Las filas

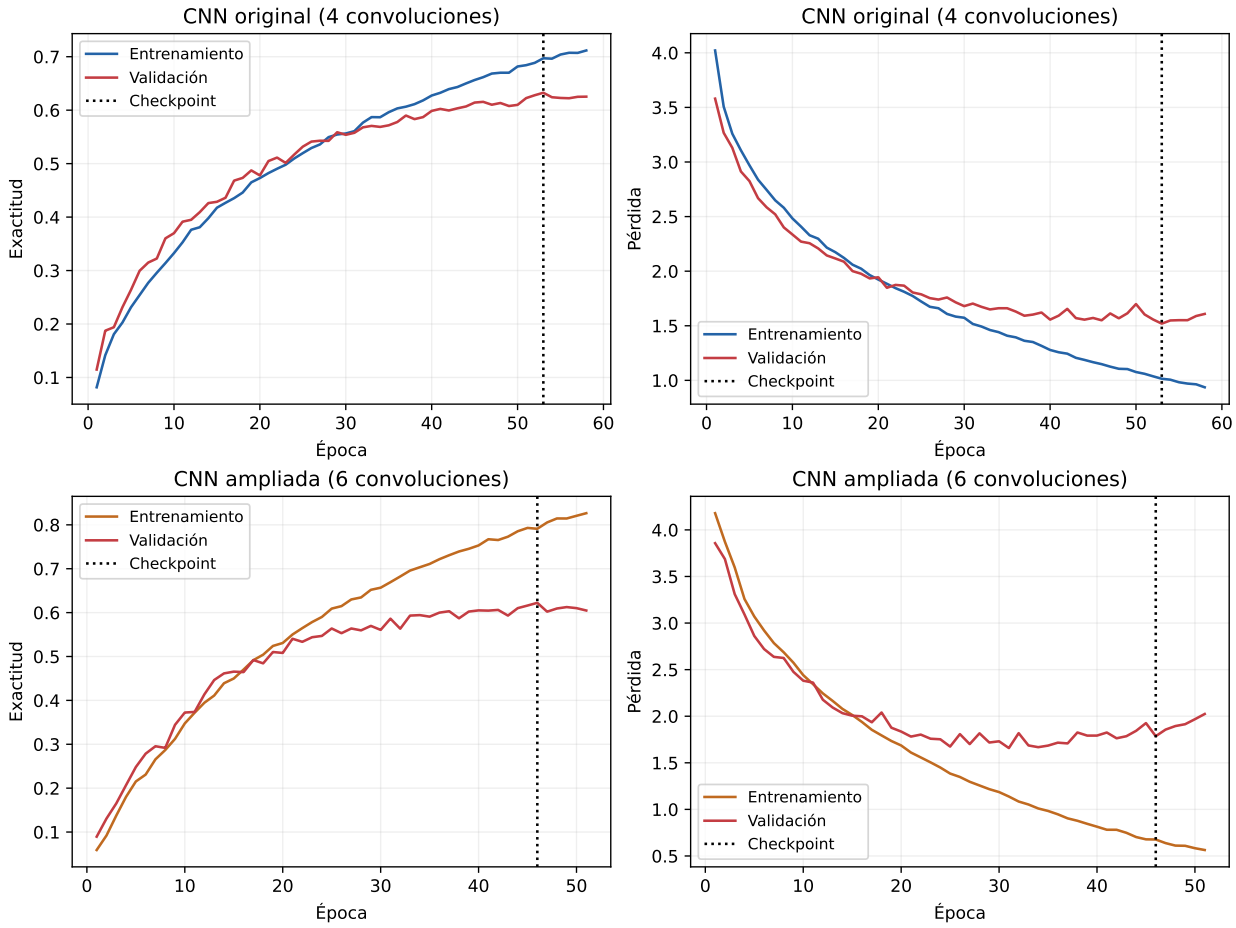


Figura 5: CNN original y ampliada A4: pérdida y exactitud online/validación, con checkpoint por F1. Se muestran 58 y 51 épocas completas, respectivamente.

Tabla 5
Modelo A4 seleccionado: cuatro clases con mayor y cuatro con menor F1.

ID	Clase	Precisión	Recall	F1	Soporte
60	cautleya spicata	1.0000	1.0000	1.0000	8
63	silverbush	1.0000	1.0000	1.0000	8
59	pink-yellow dahlia	0.9444	1.0000	0.9714	17
65	osteospermum	0.9000	1.0000	0.9474	9
2	canterbury bells	0.0000	0.0000	0.0000	6
3	sweet pea	0.0000	0.0000	0.0000	6
31	garden phlox	0.0000	0.0000	0.0000	7
38	siam tulip	0.0000	0.0000	0.0000	5

Empates por ID. Las 104 clases se incluyen en el anexo y CSV.

Tabla 6
Principales confusiones del checkpoint A4 seleccionado.

Clase real	Predicción	Imágenes
carnation	rose	12
common tulip	rose	12
anthurium	rose	10
daisy	common dandelion	8
windflower	wild rose	8
camellia	rose	8

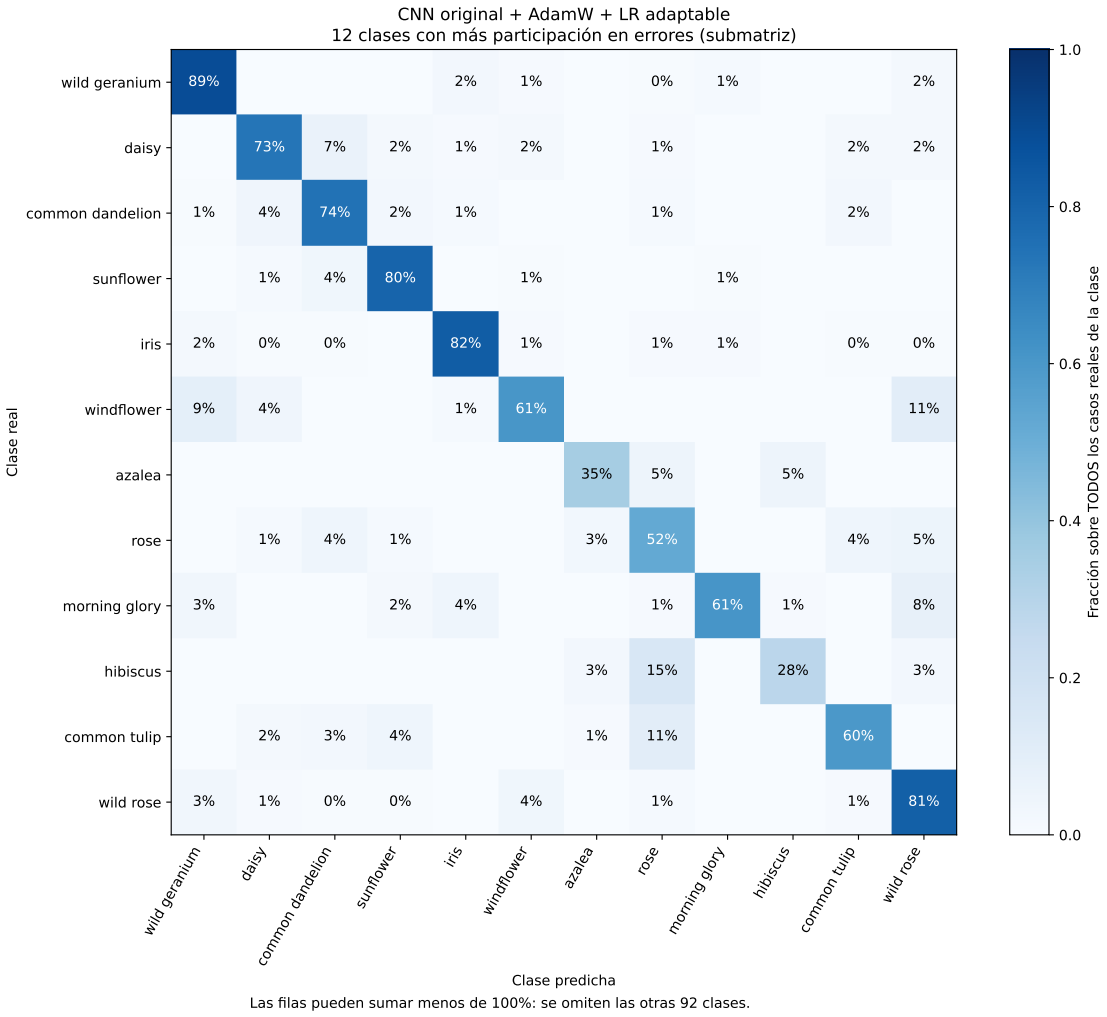


Figura 6: Checkpoint A4 seleccionado: 12 clases con mayor participación en errores. Filas reales, columnas predichas, porcentajes normalizados sobre todos los casos reales de cada clase.

de la submatriz pueden sumar menos de 100 %, pues omiten las otras clases. La matriz completa y las predicciones se conservan en CSV, además de la visualización completa del anexo.

8.5. Conclusiones y limitaciones

Las CNN históricas aprovechan la estructura espacial de las imágenes con muchos menos parámetros que la MLP evaluada, cuyo bajo ajuste y predicciones concentradas limitan su utilidad. La mayor profundidad no mejoró esta validación y sus curvas sugieren mayor sobreajuste. En el par complementario F, la regularización conjunta mejora los mejores modelos y reduce su brecha, pero no supera al control en F1 durante toda la trayectoria: la época común 34 muestra el intercambio entre velocidad de ajuste, pérdida y F1. No se atribuye el resultado a una sola técnica.

Se utiliza una semilla y validación para elegir checkpoints e hiperparámetros; faltan prueba independiente y variabilidad entre semillas. Los recálculos de predicciones no verifican nuevamente su inferencia sobre las imágenes originales; las pérdidas y train limpio dependen de los históricos. Se preservan familias, configuraciones y límites para que el notebook distinga reproducir análisis de volver a entrenar. Los siguientes experimentos serían evaluar la MLP en train limpio y repetir intervenciones controladas con varias semillas; no son requisitos satisfechos por los resultados actuales.

Referencias

Bryan Clark. What Is Image Classification? | IBM — ibm.com. https://www.ibm.com/think/topics/image-classification, 2025. [Accessed 28-09-2026].

Kaggle. Petals to the Metal - Flower Classification on TPU — kaggle.com. https://www.kaggle.com/competitions/tpu-getting-started/overview, s.f. [Accessed 28-09-2026].

Maria-Elena Nilsback and Andrew Zisserman. Automated flower classification over a large number of classes. In *2008 Sixth Indian Conference on Computer Vision, Graphics & Image Processing*, pages 722–729. IEEE, 2008. doi: 10.1109/ICVGIP.2008.47.

Anexo: métricas completas y matriz de confusión

Las métricas se derivan de las 3,712 predicciones de validación del modelo A4-CNN-AdamW/LR, checkpoint 61. El soporte total es 3,712; los ceros por clase se conservan al promediar F1 macro. No se trata de métricas de test.

Tabla 7: Métricas de las 104 clases. A4-CNN-AdamW/LR, checkpoint 61.

ID	Clase	Precisión	Recall	F1	Soporte
0	pink primrose	0.8767	0.8101	0.8421	79
1	hard-leaved pocket orchid	1.0000	0.5714	0.7273	7
2	canterbury bells	0.0000	0.0000	0.0000	6
3	sweet pea	0.0000	0.0000	0.0000	6
4	wild geranium	0.7778	0.8878	0.8292	205
5	tiger lily	0.3659	0.6000	0.4545	25
6	moon orchid	0.3333	0.4000	0.3636	5
7	bird of paradise	0.8438	0.8710	0.8571	31
8	monkshood	0.7600	0.7600	0.7600	25
9	globe thistle	0.4872	0.7917	0.6032	24
10	snapdragon	0.4839	0.3750	0.4225	40
11	colt's foot	0.7778	0.5385	0.6364	13
12	king protea	0.7931	0.8519	0.8214	27
13	spear thistle	0.7108	0.7662	0.7375	77
14	yellow iris	0.7333	0.8333	0.7801	66
15	globe-flower	1.0000	0.5000	0.6667	6
16	purple coneflower	0.9375	0.9375	0.9375	16
17	peruvian lily	0.4286	0.2143	0.2857	14
18	balloon flower	0.3684	0.2692	0.3111	26
19	giant white arum lily	1.0000	0.7500	0.8571	8
20	fire lily	0.8000	0.6667	0.7273	6
21	pincushion flower	0.5714	0.5714	0.5714	28
22	fritillary	0.8000	0.8571	0.8276	14
23	red ginger	0.8333	0.8333	0.8333	6
24	grape hyacinth	0.4138	0.5000	0.4528	24
25	corn poppy	0.6316	0.5000	0.5581	24
26	prince of wales feathers	0.5000	0.3333	0.4000	6
27	stemless gentian	0.7692	1.0000	0.8696	10
28	artichoke	0.5676	0.6176	0.5915	34
29	sweet william	0.3462	0.5625	0.4286	32
30	carnation	0.4000	0.3226	0.3571	31
31	garden phlox	0.0000	0.0000	0.0000	7
32	love in the mist	0.6667	0.2857	0.4000	7
33	cosmos	1.0000	0.1667	0.2857	6
34	alpine sea holly	1.0000	0.2000	0.3333	5
35	ruby-lipped cattleya	0.8333	0.4545	0.5882	11
36	cape flower	0.8000	0.9412	0.8649	17
37	great masterwort	0.7500	0.7500	0.7500	8
38	siam tulip	0.0000	0.0000	0.0000	5
39	lenten rose	0.6316	0.5714	0.6000	21
40	barberton daisy	0.5625	0.5000	0.5294	18
41	daffodil	0.4444	0.4286	0.4364	28
42	sword lily	0.3333	0.0556	0.0952	18
43	poinsettia	0.4565	0.6562	0.5385	32
44	bolero deep blue	0.0000	0.0000	0.0000	5
45	wallflower	0.7083	0.6800	0.6939	50
46	marigold	0.6000	0.6486	0.6234	37
47	buttercup	0.7639	0.7237	0.7432	76
48	daisy	0.7258	0.7317	0.7287	123
49	common dandelion	0.7052	0.7439	0.7240	164
50	petunia	0.6364	0.4828	0.5490	58
51	wild pansy	0.8571	0.6000	0.7059	30
52	primula	0.4737	0.2727	0.3462	33
53	sunflower	0.6948	0.7985	0.7431	134

Tabla de clases (continuación)

ID	Clase	Precisión	Recall	F1	Soporte
54	lilac hibiscus	1.0000	0.7273	0.8421	11
55	bishop of llandaff	1.0000	0.8824	0.9375	17
56	gaura	0.5556	0.5769	0.5660	26
57	geranium	0.7391	0.9444	0.8293	18
58	orange dahlia	0.8333	1.0000	0.9091	10
59	pink-yellow dahlia	0.9444	1.0000	0.9714	17
60	cautleya spicata	1.0000	1.0000	1.0000	8
61	japanese anemone	0.6250	0.6250	0.6250	8
62	black-eyed susan	0.6818	0.5556	0.6122	27
63	silverbush	1.0000	1.0000	1.0000	8
64	californian poppy	0.8889	1.0000	0.9412	16
65	osteospermum	0.9000	1.0000	0.9474	9
66	spring crocus	0.5000	0.1667	0.2500	6
67	iris	0.7833	0.8246	0.8034	228
68	windflower	0.5974	0.6053	0.6013	76
69	tree poppy	0.8824	0.5556	0.6818	27
70	gazania	0.5000	0.5333	0.5161	30
71	azalea	0.3784	0.3500	0.3636	40
72	water lily	0.7347	0.7347	0.7347	49
73	rose	0.3763	0.5224	0.4375	134
74	thorn apple	0.7143	0.5556	0.6250	36
75	morning glory	0.7013	0.6067	0.6506	89
76	passion flower	0.8056	0.8286	0.8169	35
77	lotus	0.7667	0.5610	0.6479	41
78	toad lily	0.5200	0.5200	0.5200	25
79	anthurium	0.3415	0.4118	0.3733	34
80	frangipani	0.8235	0.6222	0.7089	45
81	clematis	0.3750	0.3103	0.3396	29
82	hibiscus	0.3333	0.2821	0.3056	39
83	columbine	0.4000	0.1818	0.2500	33
84	desert-rose	0.6667	0.4444	0.5333	9
85	tree mallow	0.6667	0.4444	0.5333	9
86	magnolia	0.4038	0.6000	0.4828	35
87	cyclamen	0.5476	0.5349	0.5412	43
88	watercress	0.5667	0.6071	0.5862	28
89	canna lily	0.6364	0.5385	0.5833	13
90	hippeastrum	0.4286	0.3871	0.4068	31
91	bee balm	0.7000	0.4375	0.5385	32
92	pink quill	0.5000	0.1429	0.2222	7
93	foxglove	0.5472	0.7073	0.6170	41
94	bougainvillea	0.4828	0.3684	0.4179	38
95	camellia	0.3939	0.3514	0.3714	37
96	mallow	0.4348	0.3448	0.3846	29
97	mexican petunia	0.7000	0.5833	0.6364	12
98	bromelia	0.5455	0.6000	0.5714	10
99	blanket flower	0.7000	1.0000	0.8235	7
100	trumpet creeper	0.0000	0.0000	0.0000	9
101	blackberry lily	0.7500	0.4286	0.5455	7
102	common tulip	0.6182	0.5965	0.6071	114
103	wild rose	0.6875	0.8148	0.7458	216

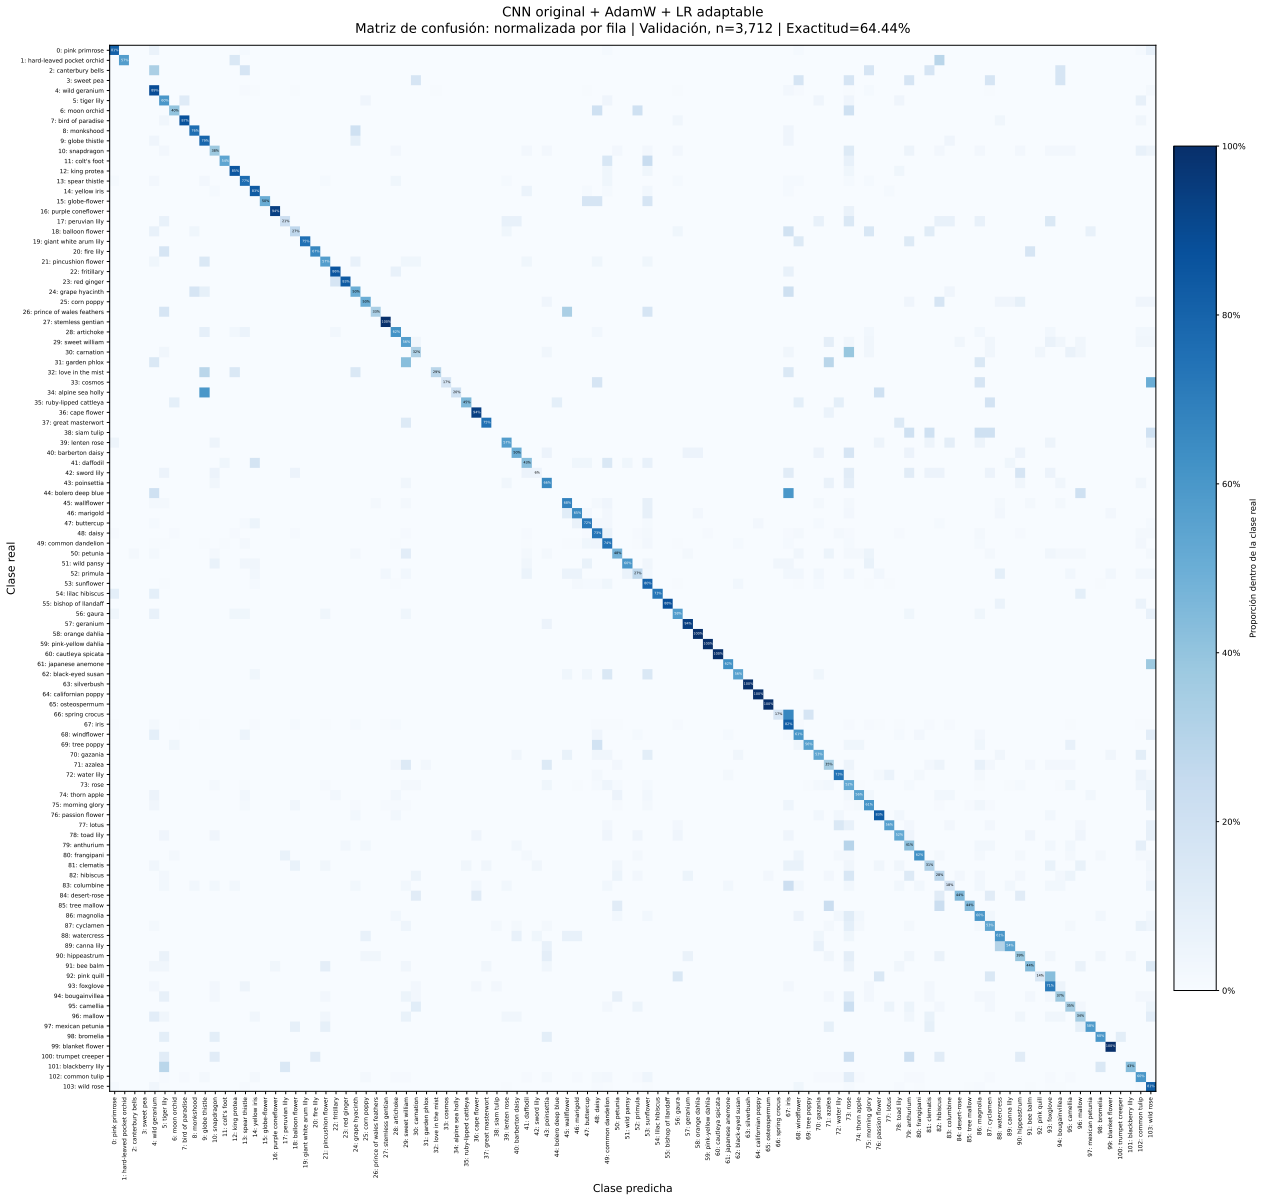


Figura 7: Matriz completa normalizada por clase real del modelo seleccionado (104 clases). La diagonal representa recall; la vista de foco del cuerpo permite leer los errores más frecuentes.