Clasificación automática de 104 tipos de flores con redes neuronales profundas*

Angel Eduardo-Luna[a,1], Andrea Estefanía De la Peña Contreras[a,2], Jannette Cristina Flores Rodríguez[a,3], Rey Iván de la Fuente Chávez[a,4] and Andrés Huerta Robinson[a,5]

[a]*Escuela de Ingeniería y Ciencias, Tecnológico de Monterrey, Monterrey, Nuevo León, México*

INFORMACIÓN

Palabras clave:
Clasificación de imágenes
Redes neuronales convolucionales
Regularización
Desbalance de clases
F1 macro
Flores

Resumen

Se clasifican 104 categorías de flores de la competencia *Petals to the Metal* con redes entrenadas desde cero a 112×112, usando 12,753 imágenes de entrenamiento y 3,712 de validación, con un desbalance de 18 a 782 imágenes por clase. A partir de una CNN de referencia de cuatro convoluciones, se cambia un factor a la vez: una MLP como línea base, una CNN con dos convoluciones más, la eliminación de la regularización, pesos por clase en la pérdida, una tasa de aprendizaje menor y menos dropout. La CNN de referencia es la mejor, con F1 macro de 0.5784 y exactitud de 64.06 % en validación. La MLP no logra aprender (F1 de 0.018) y la red más profunda no mejora (0.566). Sin regularización, la brecha de F1 entre entrenamiento y validación sube de 0.235 a 0.344, y los pesos por clase bajan el F1 a 0.488 porque sacrifican las clases frecuentes por las raras. Todas las CNN se estancan cerca de 64 % de exactitud por dos límites que actúan juntos: la capacidad de una red pequeña entrenada desde cero a 112×112, que no alcanza a separar flores parecidas, y los pocos datos por clase, que impiden aprovechar más capacidad: dos convoluciones más aceleran la memorización del entrenamiento, pero no mejoran la validación. Cada configuración usa una sola semilla; el código, los historiales y un notebook que reproduce los resultados están en un repositorio público.

Índice

1. Resumen y objetivos 1

2. Contexto del problema 2

3. Descripción del dataset 2
3.1. Origen . . . 2
3.2. Tamaño y estructura . . . 2
3.3. Ejemplos de las imágenes . . . 3
3.4. Balance de clases y métrica de evaluación . . . 3
3.5. Implicaciones para el proyecto . . . 3

4. Algoritmos y aplicaciones 4
4.1. Algoritmos clásicos de aprendizaje automático . . . 4
4.2. CNN propia entrenada desde cero . . . 4
4.3. Transferencia de aprendizaje . . . 4
4.4. Aplicaciones y alcance . . . 5

5. Metodología 5
5.1. Representación de las arquitecturas implementadas 5
5.2. Preprocesamiento y aumento de datos . . . 6
5.3. Pérdida y actualización de parámetros . . . 6
5.4. Pesos por clase . . . 6

6. Protocolo experimental 6
6.1. Condiciones comunes . . . 6
6.2. Un cambio a la vez . . . 6
6.3. Métricas de entrenamiento comparables con validación . . . 6
6.4. Alcance de la evaluación . . . 6
6.5. Reproducibilidad . . . 6

7. Resultados 7
7.1. Desbalance de clases . . . 7
7.2. Arquitecturas: MLP, CNN de referencia y CNN ampliada . . . 7
7.3. Comparación con el Avance 4 . . . 7
7.4. F1 por clase de la CNN de referencia . . . 8
7.5. Pesos por clase . . . 8
7.6. Efecto de la regularización . . . 9
7.7. Hiperparámetros . . . 9
7.8. Reducción de datos con Distribution Matching . . . 10

8. Análisis 10
8.1. Por qué la CNN supera a la MLP . . . 10
8.2. Por qué la CNN más profunda empeoró . . . 10
8.3. Qué aporta la regularización . . . 11
8.4. Sensibilidad a los hiperparámetros . . . 11
8.5. Por qué los pesos por clase no ayudaron . . . 11
8.6. Limitaciones . . . 12

9. Conclusiones 12
9.1. Trabajo futuro . . . 12

10. Conclusión individual (Angel Luna) 12

1. Resumen y objetivos

Este reporte final compara, con la misma partición de validación, una CNN de referencia contra variantes que cambian un solo factor cada una. El objetivo es responder cinco preguntas sobre la clasificación de 104 categorías de flores:

* Situación problema: Red convolutiva, reporte final. Diseño de Redes Neuronales y Aprendizaje Profundo (TC2035.201). Basado en la competencia *Petals to the Metal – Flower Classification on TPU* (Kaggle).

[1]Matrícula: A00842657
[2]Matrícula: A00840973
[3]Matrícula: A01255711
[4]Matrícula: A01709445
[5]Matrícula: A00838626

1. Si extraer patrones espaciales mejora la clasificación, comparando la CNN con una red totalmente conectada (MLP) sobre las mismas imágenes.
2. Si una CNN más profunda generaliza mejor que la original.
3. Cuánto aportan la regularización (dropout, aumento de datos y decaimiento de pesos) a la generalización.
4. Si ponderar la pérdida por clase compensa el desbalance del conjunto.
5. Qué tan sensible es el modelo a la tasa de aprendizaje y al dropout.

Además de exactitud y F1 macro, se reportan curvas de pérdida, exactitud y F1 de entrenamiento y validación, el F1 por clase, el desbalance de los datos y matrices de confusión. Para que la brecha de generalización sea comparable, las métricas de entrenamiento se miden sobre imágenes sin aumento y con la red en modo inferencia. Todas las cifras se reconstruyen con un notebook a partir de los historiales versionados de cada corrida (Sección 6.5).

2. Contexto del problema

Poder identificar una flor a partir de una fotografía tiene aplicaciones reales. Una de ellas es el apoyo a plataformas de ciencia ciudadana y de monitoreo de biodiversidad. Por ejemplo, iNaturalist ha acumulado más de 300 millones de observaciones hechas por personas comunes y utiliza un modelo de visión por computadora, entrenado con esas mismas observaciones, para sugerir la especie a partir de una fotografía (iNaturalist, 2026). Sin este apoyo automático, cada observación dependería de que una persona la revisara detenidamente, lo que haría el proceso lento y difícil de escalar. Automatizar parte de la tarea mejora la eficiencia y aporta en gran medida a la obtención de datos sobre biodiversidad. Otra aplicación es la educativa, por ejemplo, en aplicaciones para estudiantes o visitantes de jardines botánicos que permitan reconocer flores y consultar información sobre ellas. También existe un interés comercial: en México la floricultura es una actividad económica importante, y el Estado de México es el principal productor de clavel y de crisantemo, con el 81.4 % del valor nacional de las flores de la temporada de otoño de 2021 (Secretaría de Agricultura y Desarrollo Rural, 2022). Este proyecto es una versión a menor escala de este tipo de sistemas.

El reto es que la diversidad del mundo natural es enorme: se estima que existen más de 5,000 especies de mamíferos, 10,000 de aves y 30,000 de peces, pero hay más de 400,000 tipos de flores (Kaggle, s.f.). Distinguir entre ellas llega a requerir conocimiento especializado y, incluso para una persona con experiencia, muchas flores son visualmente muy parecidas entre sí. Identificarlas de forma manual es lento y no es escalable cuando se tienen miles de fotografías, por lo que resulta valioso contar con modelos de clasificación de imágenes que reconozcan el tipo de flor de forma automática (Clark, 2025).

Este proyecto parte de la competencia *Petals to the Metal*, de Kaggle, cuyo reto es construir un modelo que identifique el tipo de flor en un conjunto de imágenes. La competencia se limita a 104 clases de flores y consiste en un problema de clasificación multiclase de imágenes en el que el modelo debe identificar rasgos finos como la forma, la estructura y el color para distinguir entre categorías cercanas.

Tabla 1
Particiones del conjunto de datos.

Partición	Imágenes	%	¿Etiquetado?
Entrenamiento	12,753	53.5	Sí
Validación	3,712	15.6	Sí
Prueba	7,382	31.0	No
Total	23,847	100.0	

Este problema tiene varias dificultades que lo hacen relevante desde un enfoque de redes neuronales. Primero, las clases son heterogéneas, ya que algunas solo tienen un subtipo de flor y otras agrupan muchas subvariedades. Además, las imágenes no fueron capturadas en el mismo entorno, lo que les da más variedad. Por último, el número de imágenes por clase tampoco es uniforme, por lo que, considerando la métrica de evaluación, es importante que el modelo funcione bien tanto en clases con pocos ejemplos como en aquellas con muchos.

3. Descripción del dataset

3.1. Origen

Los datos vienen de *Petals to the Metal – Flower Classification on TPU*, una competencia *Getting Started* de Kaggle cuyo objetivo es aprender a entrenar modelos en TPU (Kaggle, s.f.). Según la descripción de la competencia, las imágenes se tomaron de cinco conjuntos de datos públicos. Algunas clases son muy específicas (por ejemplo, *pink primrose*, que contiene un solo subtipo de flor) y otras agrupan muchas subvariedades (por ejemplo, *wild rose*).

Al revisar la lista de clases nos dimos cuenta de que las primeras 102 siguen exactamente el orden del conjunto Oxford 102 Flowers (Nilsback y Zisserman, 2008): 94 conservan el mismo nombre y las otras 8 se renombraron, se corrigieron o se ampliaron (por ejemplo, *oxeye daisy* pasó a ser *daisy* y *bearded iris* pasó a ser *iris*). Las dos clases extra son *common tulip* y *wild rose*. Las etiquetas están en inglés, así que usamos los nombres originales en cursiva.

3.2. Tamaño y estructura

En total hay 23,847 imágenes a color (RGB) de 104 clases, repartidas como muestra la Tabla 1. Vienen en formato TFRecord, que junta muchas imágenes en pocos archivos binarios para que la TPU las lea rápido. Cada registro tiene tres campos: `image` (la foto codificada en JPEG), `id` (un identificador único) y `class` (la etiqueta, un entero de 0 a 103). Los registros de prueba no traen `class`, porque esas etiquetas solo las tiene Kaggle para calificar.

Cada partición viene en 4 resoluciones: 192×192, 224×224, 331×331 y 512×512 píxeles, con 16 archivos TFRecord por partición, por lo que la base de datos trae 192 archivos

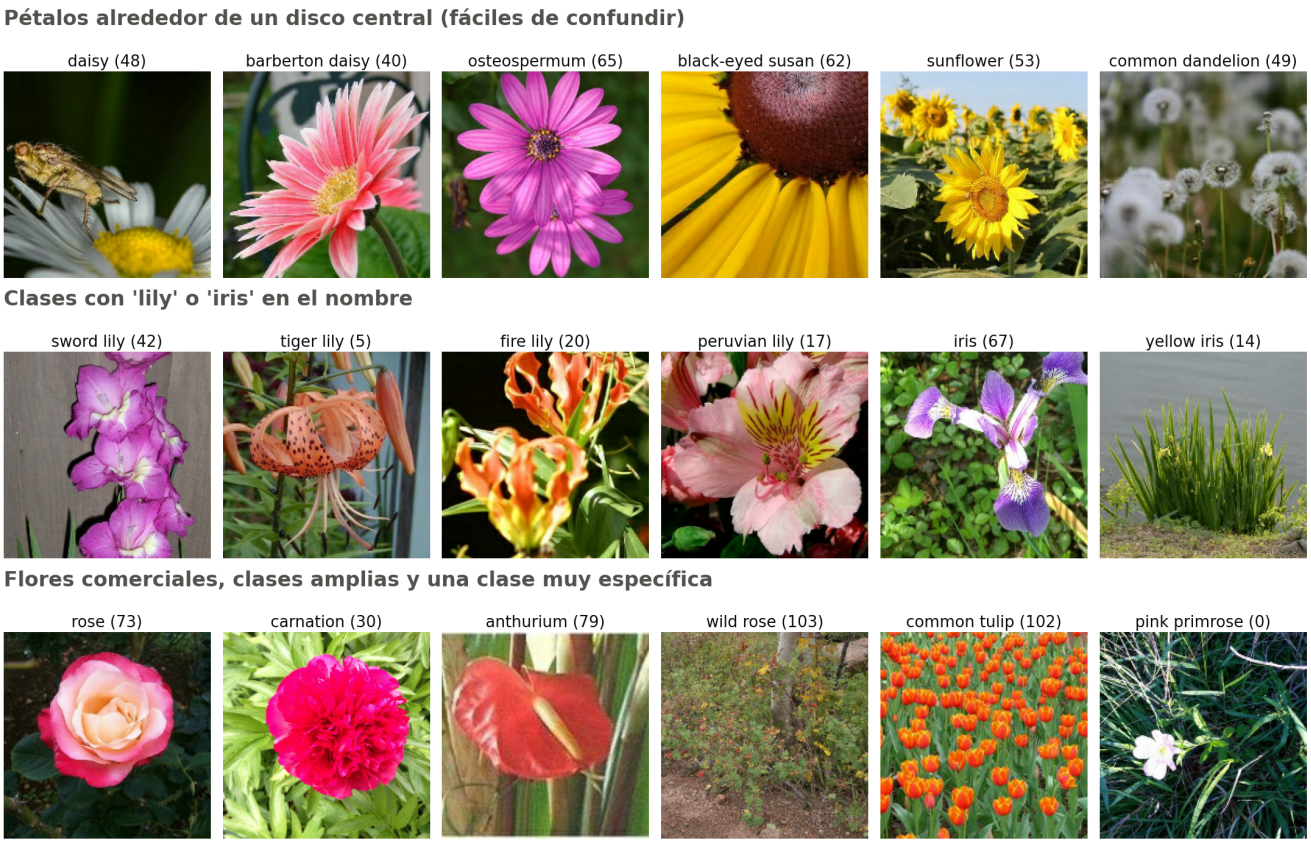


Figura 1: Ejemplos reales del conjunto de entrenamiento con su clase y número de etiqueta.

TFRecord (4 resoluciones × 3 particiones × 16 archivos) más `sample_submission.csv`. Tener varias resoluciones nos conviene porque no todas las arquitecturas se diseñaron para el mismo tamaño de entrada: ResNet50, DenseNet201 y EfficientNetB0 hacen uso de 224 × 224, mientras que las EfficientNet más grandes usan resoluciones mayores. Para dimensionar el problema, una sola imagen de 224 × 224 ya tiene 150,528 valores.

En las ejecuciones de este trabajo se leen los TFRecord de 224×224, pero se redimensionan las imágenes a 112×112 antes de entrar a cualquiera de los modelos. La resolución de origen y la entrada efectiva de entrenamiento son, por tanto, distintas. Se conservan las particiones y etiquetas originales.

3.3. Ejemplos de las imágenes

La tabla 2 muestra algunas clases concretas y lo que cada una nos dice sobre el problema. Además, dentro de una misma clase, las fotos cambian mucho de escala, pose e iluminación (Nilsback & Zisserman, 2008)

La Figura 1 muestra fotos reales del conjunto de entrenamiento.

3.4. Balance de clases y métrica de evaluación

Con 12,753 imágenes de entrenamiento y 104 clases, tenemos en promedio 123 imágenes por clase (12,753/104 ≈ 122.6). Sin embargo, las clases no tienen el mismo tamaño: como unas clases agrupan muchas subvariedades y otras solo una, algunas tienen muchas más imágenes que otras.

Por este desbalance, la exactitud no basta: un modelo puede acertar mucho en las clases grandes, fallar en las clases pequeñas y aún verse bien. Por esto mismo, Kaggle califica con el F1 macro (Kaggle, s.f.). Para cada clase c se calcula la precisión P_c, la sensibilidad (*recall*) R_c y su media armónica:

$$P_c = \frac{TP_c}{TP_c + FP_c}, \quad R_c = \frac{TP_c}{TP_c + FN_c}, \tag{1}$$

$$F1_c = \frac{2\,P_c\,R_c}{P_c + R_c}, \qquad F1_{\text{macro}} = \frac{1}{104}\sum_{c=0}^{103} F1_c, \tag{2}$$

donde TP_c, FP_c y FN_c son los verdaderos positivos, falsos positivos, y falsos negativos de la clase c . Así todas las clases pesan lo mismo, sin importar cuántas imágenes tengan.

3.5. Implicaciones para el proyecto

Como Kaggle ya separa entrenamiento y validación, no hizo falta crear una partición propia: entrenamos con `train` y elegimos y evaluamos modelos e hiperparámetros con `val`. El conjunto `test` no se usó, porque no trae etiquetas y no se enviaron predicciones a Kaggle. Las imágenes vienen en

Tabla 2
Clases de ejemplo (nombre y etiqueta) más lo que ilustran.

Clase (etiqueta)	Que ilustra
sunflower (53)	Girasol. Flor grande y muy característica. Posiblemente sea de las más fáciles de identificar.
daisy (48), *barberton daisy* (40), *osteospermum* (65), *black-eyed susan* (62)	Margarita, gerbera, osteospermum y rudbeckia. Todas tienen pétalos alrededor de un disco central. Pueden surgir confusiones entre ellas.
sword lily (42), *tiger lily* (5), *fire lily* (20), *peruvian lily* (17)	Gladiola, lirio tigre, gloriosa y alstroemeria. Todas dicen *lily*, pero son de cuatro familias botánicas distintas: el modelo tiene que fijarse en la forma, no en el nombre.
iris (67), *yellow iris* (14)	Misma forma general, la diferencia principal es el color.
rose (73), *wild rose* (103)	Dos clases de rosas. *Wild rose* es amplia (varias subvariedades) y no viene de Oxford 102.
common tulip (102)	Tulipán. Clase amplia que tampoco viene de Oxford 102.
pink primrose (0)	Clase muy específica con un solo subtipo de flor.
carnation (30)	Clavel, una de las flores comerciales que se producen en el Estado de México.

JPEG con valores de 0 a 255, por lo que se decodifican y se escalan a $[0, 1]$ (Sección 5). Como las etiquetas son enteros, cada red produce 104 valores de salida, uno por clase, que se convierten en probabilidades con Softmax, y se entrena con entropía cruzada categórica dispersa.

4. Algoritmos y aplicaciones

Dado el problema planteado, su solución implica el uso de algoritmos de visión por computadora que permitan automatizar la identificación de flores, como en las aplicaciones descritas en la sección de contexto. A continuación se explica por qué los algoritmos clásicos no son adecuados y qué arquitecturas proponemos.

4.1. Algoritmos clásicos de aprendizaje automático

Algoritmos como k vecinos más cercanos (KNN), *Random Forest* (RF) y máquinas de soporte vectorial (SVM) funcionan de manera correcta con datos tabulares, pero se adaptan mal a imágenes. Una imagen de 224×224 píxeles RGB tiene $224 \cdot 224 \cdot 3 = 150{,}528$ valores, y una de 112×112, la resolución que usamos, tiene 37,632. Tratar cada valor como una característica independiente genera varios problemas:

- **KNN.** En espacios con tantas dimensiones, las distancias entre puntos dejan de ser informativas (la llamada maldición de la dimensionalidad). Además, la distancia entre píxeles no refleja similitud visual: dos fotos de la misma flor con un ligero desplazamiento o distinta iluminación quedan muy lejos entre sí. KNN guarda todo el conjunto de entrenamiento y calcula distancias contra todas las imágenes en cada predicción, lo cual es costoso.
- **Random Forest.** Cada árbol divide los datos según el valor de un solo píxel, sin considerar su posición relativa ni sus vecinos, por lo que no puede capturar formas ni texturas.
- **SVM.** Con kernel, el costo de entrenamiento crece rápidamente con el número de imágenes y de dimensiones, y sobre píxeles crudos no es invariante a desplazamientos, rotaciones ni cambios de escala, que en este conjunto son comunes.

Estos métodos requerirían extraer características manualmente (bordes, color, textura) antes de clasificar. Las redes convolucionales evitan este paso, ya que aprenden las características directamente de los píxeles.

4.2. CNN propia entrenada desde cero

Las redes neuronales convolucionales (CNN) son una alternativa especialmente adecuada para este problema debido a su capacidad para procesar información espacial (Figura 2). Mediante filtros convolucionales pueden aprender automáticamente características de las imágenes, como bordes, texturas y formas. En las capas internas pueden emplearse funciones de activación como ReLU, mientras que Softmax puede utilizarse en la salida para representar las probabilidades de las distintas clases.

Nuestra primera propuesta es una CNN propia con cuatro bloques convolucionales (de 32 a 256 filtros), *Global Average Pooling*, una capa densa de 256 neuronas con *dropout* de 0.5 y una capa de salida *softmax* de 104 neuronas. Tiene 480,936 parámetros entrenables (Tabla 3) y recibe imágenes de 112×112 píxeles.

Elegimos empezar desde cero por tres razones. Es ligera: se entrena en unos 20 minutos en una GPU de una Mac M4, lo que permite repetir experimentos. Permite estudiar de forma controlada el efecto de la regularización, de la profundidad y del desbalance, porque todo lo que la red sabe lo aprende de estos datos. Y sirve como línea base para medir cuánto aportaría un modelo preentrenado. Su reto es que, con un promedio de solo 123 imágenes por clase, existe riesgo de sobreajuste, tema que se mide en la Sección 7.6.

4.3. Transferencia de aprendizaje

La segunda alternativa es partir de una red ya entrenada en ImageNet (Deng et al., 2009), con 1.2 millones de

imágenes de 1,000 categorías, y ajustarla a las flores. Dos arquitecturas concretas son adecuadas:

- **ResNet50** (K. He et al., 2016): 50 capas con conexiones residuales, que suman la entrada de cada bloque a su salida. Esto permite entrenar redes muy profundas sin que el gradiente se desvanezca. Tiene unos 25 millones de parámetros y usa entradas de 224×224.
- **EfficientNetB0** (Tan & Le, 2019): escala de forma equilibrada la profundidad, el ancho y la resolución de la red. Con unos 5.3 millones de parámetros y entradas de 224×224 logra una exactitud en ImageNet comparable a la de ResNet50 con cinco veces menos parámetros.

Estas redes sirven con unas 123 imágenes por clase porque no aprenden desde cero: sus primeras capas ya detectan bordes, texturas y formas generales, y solo hace falta ajustar las últimas capas (o reemplazar la de salida) para distinguir las 104 clases. Así, la poca información por clase se usa para aprender lo específico de cada flor y no lo general de una imagen. Además, su entrada de 224×224 coincide con una de las resoluciones del conjunto y conserva detalles que se pierden a 112×112.

Conviene probar la transferencia de aprendizaje cuando la CNN propia deja de mejorar con más regularización o capacidad, que es lo que muestran los resultados de este trabajo (Sección 8). El repositorio ya incluye la configuración para EfficientNetB0, pero su corrida no se completó por tiempo de cómputo, por lo que queda como trabajo futuro.

4.4. Aplicaciones y alcance

Un modelo como el de este trabajo podría integrarse en una aplicación que, a partir de una fotografía, sugiera la flor más probable y sus alternativas, al estilo de iNaturalist (iNaturalist, 2026), o en herramientas educativas para jardines botánicos y escuelas. En ambos casos funcionaría como apoyo a una persona y no como identificación definitiva.

Cabe aclarar que el modelo solo puede reconocer las 104 clases presentes en el conjunto de datos: ante una flor de otra especie, elegirá la más parecida de esas 104. Una aplicación real más amplia requeriría entrenarlo con una variedad mucho mayor de especies y detectar cuándo una imagen no pertenece a ninguna clase conocida.

5. Metodología

5.1. Representación de las arquitecturas implementadas

La Figura 3 representa los tres diseños entrenados desde cero. La entrada efectiva es una imagen RGB de 112×112 píxeles, obtenida de los TFRecord de 224×224 mediante redimensionamiento bilineal con antialias.

La red **totalmente conectada de referencia** aplana los $112 \times 112 \times 3$ valores de entrada en un vector de 37,632 componentes. Aplica una capa densa de 256 unidades con ReLU, dropout (Srivastava et al., 2014) de 0.5 y una salida de 104 logits. No contiene convoluciones ni pooling. Utiliza el mismo cargador, aumentos y ciclo de entrenamiento que la CNN.

Tabla 3
Parámetros entrenables por capa de las dos CNN.

Capa	Salida	Original	Ampliada
Conv 32	$112 \times 112 \times 32$	896	896
Conv 64	$56 \times 56 \times 64$	18,496	18,496
Conv 128	$28 \times 28 \times 128$	73,856	73,856
Conv 128 (extra)	$14 \times 14 \times 128$	–	147,584
Conv 256	$14 \times 14 \times 256$	295,168	295,168
Conv 256 (extra)	$7 \times 7 \times 256$	–	590,080
Densa 256	256	65,792	65,792
Salida	104	26,728	26,728
Total		480,936	1,218,600

Todas las convoluciones son de 3×3; la densa va después del GAP. Cada convolución va seguida de max pooling de 2×2 (sin parámetros), salvo las dos extra. La salida indicada es la de la convolución, antes del pooling.

La **CNN original** emplea cuatro convoluciones de 3×3, padding *same*, ReLU y 32, 64, 128 y 256 filtros. Cada convolución va seguida de max pooling de 2×2. Las salidas de esos bloques son $56 \times 56 \times 32$, $28 \times 28 \times 64$, $14 \times 14 \times 128$ y $7 \times 7 \times 256$. Después aplica *global average pooling* (GAP) (Lin et al., 2014), que promedia cada uno de los 256 mapas de 7×7 en un solo número. El resultado es un vector de 256 valores, uno por filtro, que indica cuánto se activó ese rasgo en la imagen sin importar en qué posición apareció. GAP no tiene parámetros y, a diferencia de aplanar los $7 \times 7 \times 256 = 12{,}544$ valores, deja la capa densa siguiente en 65,792 parámetros en lugar de unos 3.2 millones, lo que reduce el riesgo de sobreajuste. Le siguen una capa densa de 256 unidades con ReLU, dropout de 0.5 y 104 logits de salida.

La **CNN ampliada** agrega dos capas convolucionales ocultas: una de 128 filtros después del tercer pooling y otra de 256 después del cuarto. Ambas usan kernel 3×3, padding *same* y ReLU, sin pooling adicional. Por tanto, esta versión tiene seis convoluciones. No se trata de dos capas densas nuevas.

La Tabla 3 desglosa los parámetros por capa. En una convolución de 3×3 con C_{in} canales de entrada y C_{out} filtros hay $(9\,C_{\text{in}} + 1)\,C_{\text{out}}$ parámetros, y en una capa densa $(n_{\text{in}} + 1)\,n_{\text{out}}$; el pooling no tiene parámetros. En la CNN original, el 61 % de los parámetros está en la última convolución, y las dos capas extra de la ampliada (737,664 parámetros) más que duplican el total. En la MLP, en cambio, la primera capa densa concentra $(37{,}632+1)\times256 = 9{,}634{,}048$ parámetros, el 99.7 % del total.

La convolución comparte los pesos del filtro entre posiciones y analiza vecindarios de píxeles. Así puede aprender bordes, texturas y partes de pétalos antes de combinarlos. Una capa densa sobre píxeles aplanados asigna pesos independientes a cada posición y no impone esta estructura local.

Esta diferencia motiva la comparación, pero la mejora debe comprobarse con las métricas.

5.2. Preprocesamiento y aumento de datos

Se decodifica cada JPEG como RGB, se convierten sus valores a float32, se normalizan mediante $x_{\text{norm}} = x/255$ y se redimensionan a 112×112. Las etiquetas son enteros entre 0 y 103. Se mantiene la separación de archivos original entre entrenamiento y validación, sin incorporar imágenes de validación al entrenamiento.

Solo en entrenamiento se aplican volteo horizontal, rotación aleatoria de factor 0.05, zoom de 0.1 y contraste de 0.1. Los valores resultantes se recortan a $[0, 1]$. Los aumentos se calculan después de la caché y del mezclado, por lo que cambian entre épocas. La validación usa imágenes deterministas sin aumentos.

5.3. Pérdida y actualización de parámetros

Los modelos producen 104 logits z_k. La entropía cruzada se calcula directamente sobre ellos, sin añadir una segunda softmax a la pérdida:

$$L = -\log\left(\frac{\exp(z_c)}{\sum_{k=1}^{104}\exp(z_k)}\right), \tag{3}$$

donde c es la clase verdadera. Para visualizar la confianza se transforma la salida mediante softmax; esta confianza no constituye una evaluación de calibración.

Todas las redes se optimizan con AdamW (Loshchilov & Hutter, 2019) (decaimiento de pesos desacoplado de 0.01, sin aplicarlo a los sesgos) y una tasa inicial de 10^{-3} que se reduce a la mitad cuando la pérdida de validación no mejora en dos épocas, hasta 10^{-5}.

5.4. Pesos por clase

Para contrarrestar el desbalance (Sección 7.1), una variante pondera la pérdida de cada imagen según su clase (H. He & Garcia, 2009):

$$w_c = \frac{N}{K\, n_c}, \tag{4}$$

donde $N = 12{,}753$ es el total de imágenes, $K = 104$ el número de clases y n_c las imágenes de la clase c. Una clase de tamaño promedio recibe peso 1; las clases de 18 imágenes reciben 6.8 y *iris* (782) recibe 0.16. Como $\sum_c w_c n_c = N$, la escala total de la pérdida no cambia.

6. Protocolo experimental

6.1. Condiciones comunes

Todos los experimentos usan los mismos 12,753 ejemplos de entrenamiento y 3,712 de validación de las 104 clases, la semilla 0 y lotes de 64 imágenes. La *referencia* es la CNN de cuatro convoluciones elegida en el Avance 4: dropout de 0.5 antes de la salida, aumento de datos solo en entrenamiento (volteo horizontal, rotación, zoom y contraste), AdamW con decaimiento de pesos de 0.01 (Loshchilov & Hutter, 2019), tasa inicial de 10^{-3} reducida a la mitad cuando la pérdida de validación no mejora en dos épocas (mínimo 10^{-5}), entrada de 112×112 y hasta 150 épocas. El entrenamiento se detiene tras 12 evaluaciones sin mejorar el F1 macro de validación y se conserva el checkpoint con mayor F1 macro; todas las métricas reportadas corresponden a ese checkpoint, no a la última época.

6.2. Un cambio a la vez

Para atribuir cada diferencia a una causa, cada experimento modifica un solo factor respecto a la referencia: la arquitectura (MLP o CNN ampliada), la pérdida (pesos por clase), la regularización o un hiperparámetro (tasa de aprendizaje o dropout). La única excepción declarada es la variante *sin regularización*, que retira a la vez dropout, aumento y decaimiento de pesos (Adam en lugar de AdamW), para medir su efecto conjunto.

6.3. Métricas de entrenamiento comparables con validación

Las métricas que reporta el ciclo de entrenamiento se calculan con aumento y dropout activos, por lo que no son comparables con validación. Para medir la brecha de generalización, en cada época se evalúan además 3,712 imágenes fijas de entrenamiento (el mismo tamaño que validación) sin aumento y con la red en modo inferencia. Con ellas se calculan la pérdida, la exactitud y el F1 macro de entrenamiento. La *brecha F1* es el F1 macro de ese subconjunto menos el de validación, ambos en la época del checkpoint.

6.4. Alcance de la evaluación

La validación se usa para elegir el checkpoint y comparar configuraciones; sus métricas no son una estimación independiente de generalización. Todas las métricas de este reporte se calculan sobre validación, que sí tiene etiquetas. El conjunto de prueba no trae etiquetas (solo las tiene Kaggle) y no se enviaron predicciones a la competencia, por lo que no se reporta un puntaje de prueba. Cada configuración se entrenó con una sola semilla, por lo que diferencias de pocas milésimas de F1 macro no se interpretan como mejoras. Los resultados de este documento se generaron con TensorFlow 2.18 en una GPU Apple M4 (`tensorflow-metal`); las corridas del Avance 4 se hicieron con PyTorch/DirectML, por lo que sus cifras no se mezclan con las de este reporte.

6.5. Reproducibilidad

El código, las configuraciones y los resultados están en el repositorio público del equipo:

https://github.com/Lunaaaalj/NeuralNetworksTeamEnvironment

El `README` explica la instalación y los comandos. El notebook `notebooks/reporte_final.ipynb` reconstruye de principio a fin la tabla de resultados (`reports/final/resultados.csv`), las tablas y las figuras de este documento, a partir de los `history.csv`, `summary.json` y `eval_report.json` versionados de cada experimento; con `RUN_TRAINING = True` también vuelve a entrenarlos. La matriz de experimentos está en

Tabla 4
Arquitecturas comparadas con los mismos datos de validación (3,712 imágenes).

Modelo	Parámetros	Época	Exact. (%)	F1 entr.	Brecha F1	Tiempo (min)	F1 macro
MLP	9,660,776	62/74	14.36	0.0192	+0.0014	6.9	0.0178
CNN de referencia	480,936	91/103	64.06	0.8138	+0.2354	19.7	**0.5784**
CNN ampliada (6 conv.)†	1,218,600	41/49	63.77	0.7936	+0.2273	17.1	0.5663

Época: checkpoint elegido por F1 macro / épocas ejecutadas. F1 entr.: F1 macro sobre 3,712 imágenes fijas de entrenamiento sin aumento ni dropout, en la misma época. Brecha F1 = F1 entr. − F1 macro de validación. Todas a 112×112, entrenadas desde cero con semilla 0. †La corrida se interrumpió en la época 50 por un bloqueo de la GPU; se reporta su mejor checkpoint.

`scripts/run_final.py` y la configuración de referencia en `configs/final.yaml`. El código puede registrar cada corrida en Weights & Biases (Biewald, 2020), pero en las corridas de este reporte ese registro estuvo desactivado: las métricas por época se guardan en los `history.csv` del repositorio, para que cualquiera pueda consultarlas sin una cuenta externa.

7. Resultados

Todas las cifras de esta sección provienen de `reports/final/resultados.csv`, que el notebook de la Sección 6.5 reconstruye a partir de los `history.csv` y `eval_report.json` de cada corrida. Salvo que se indique otra cosa, las métricas son de validación (3,712 imágenes) en el checkpoint con mayor F1 macro.

7.1. Desbalance de clases

El conjunto de entrenamiento tiene 12,753 imágenes repartidas de forma muy desigual entre las 104 clases (Figura 4). La clase más pequeña tiene 18 imágenes (*moon orchid*, *bolero deep blue* y *alpine sea holly*) y la más grande 782 (*iris*): una razón de 43:1. La mediana es de 88 imágenes y la media de 122.6; la media queda por encima de la mediana porque unas pocas clases concentran los datos: las 10 más grandes reúnen el 40 % de las imágenes, mientras que 24 clases tienen menos de 30. El rango intercuartílico va de 32.5 a 125.5 imágenes. Validación conserva exactamente las mismas proporciones (de 5 a 228 imágenes por clase), de modo que las clases raras tienen también muy pocos ejemplos para evaluarlas: el F1 de una clase con 5 imágenes de validación cambia en más de 0.15 con un solo acierto.

7.2. Arquitecturas: MLP, CNN de referencia y CNN ampliada

La Tabla 4 resume las arquitecturas y la Figura 5 muestra sus curvas de pérdida, exactitud y F1 macro en entrenamiento y validación. La CNN de referencia alcanza un F1 macro de 0.5784 y una exactitud de 64.06 %; la MLP, con 20 veces más parámetros, se queda en 0.0178 y 14.36 %. La CNN ampliada llega a 0.5663, por debajo de la referencia. Su corrida se interrumpió en la época 50 por un bloqueo de la GPU; como su F1 de validación llevaba ocho épocas estable alrededor de 0.564 y la tasa de aprendizaje ya había bajado a 3×10^{-5}, es poco probable que hubiera alcanzado a la referencia.

Las curvas muestran tres comportamientos distintos:

- **CNN de referencia: sobreajuste moderado y controlado.** Las dos curvas avanzan juntas durante unas 15 épocas y después se separan. La pérdida de validación toca su mínimo en la época 54 (1.464) y después apenas sube (1.486 al final), mientras el F1 de validación sigue mejorando poco a poco hasta la época 91. En el checkpoint, el F1 de entrenamiento es 0.8138 y el de validación 0.5784: una brecha de 0.235.
- **CNN ampliada: el mismo techo, alcanzado antes.** Con 2.5 veces más parámetros aprende el entrenamiento más rápido (en la época 41 su F1 de entrenamiento es 0.794 frente a 0.638 de la referencia), pero su validación se estanca en el mismo nivel. Su pérdida de validación toca su mínimo antes (época 34) y después sube de 1.555 a 1.602, una señal de sobreajuste más clara que en la referencia.
- **MLP: infraajuste.** Entrenamiento y validación casi coinciden (brecha de F1 de 0.001) y ambas son muy bajas. La red no memoriza: no logra aprender. Solo predice 11 de las 104 clases y tiene F1 = 0 en 93.

En las tres redes, la curva gris queda por debajo de la azul: el aumento de datos y el dropout hacen que las métricas del ciclo de entrenamiento parezcan peores de lo que el modelo realmente rinde sobre imágenes de entrenamiento.

La Tabla 5 justifica conservar el checkpoint con mayor F1 macro y no la última época. Entre la época 91 y la 103, el modelo sigue ajustando un poco el entrenamiento (la pérdida baja de 0.557 a 0.551), pero el F1 de validación cae de 0.5784 a 0.5731 y su pérdida sube. La diferencia entre exactitud (64.06 %) y F1 macro (0.578) también es informativa: la exactitud cuenta aciertos sobre todas las imágenes y la dominan las clases grandes; el F1 macro promedia por clase, así que pesa igual una clase de 18 imágenes que *iris* con 782.

7.3. Comparación con el Avance 4

La Tabla 6 contrasta estas corridas con las del Avance 4. El F1 de la referencia se reproduce (0.5745 frente a 0.5784) aunque cambió el *framework*, lo que da confianza en la comparación. Lo que cambia es la brecha: medida con aumento y dropout activos, como en el Avance 4, la brecha de exactitud de la referencia era de 0.105; medida sobre imágenes limpias es de 0.189 en exactitud y de 0.235 en F1 macro. El Avance 4 subestimaba el sobreajuste a casi la mitad. En la CNN ampliada, que en el Avance 4 se entrenó

Tabla 5
CNN de referencia en la época elegida y al terminar el entrenamiento.

Métrica	Elegida (91)	Última (103)
Entrenamiento		
Exactitud (%)	83.00	83.05
F1 macro	0.8138	0.8145
Pérdida	0.557	0.551
Validación		
Exactitud (%)	64.06	63.95
F1 macro	0.5784	0.5731
Pérdida	1.483	1.486

Entre paréntesis, la época. Entrenamiento: 3,712 imágenes fijas sin aumento, en modo inferencia.

con Adam y tasa fija, la misma política de la referencia reduce su desventaja de 0.024 a 0.012 puntos de F1, pero no la elimina.

7.4. F1 por clase de la CNN de referencia

El F1 macro de 0.578 esconde mucha variación entre clases (Tabla 7). La mediana por clase es 0.600; 16 clases superan 0.8 y 13 quedan por debajo de 0.3. Las mejores son flores con forma o color muy característicos (*pink-yellow dahlia* y *cautleya spicata* con F1 de 1.0, *cape flower* y *purple coneflower* con 0.97). Cinco clases tienen F1 = 0: *bolero deep blue*, *siam tulip*, *canterbury bells*, *pink quill* y *garden phlox*. Todas tienen entre 18 y 24 imágenes de entrenamiento y entre 5 y 7 de validación, y el modelo nunca las predice.

El tamaño de la clase explica solo una parte de estos resultados (Figura 7). Las 10 clases más pequeñas tienen un F1 promedio de 0.361 y las 10 más grandes de 0.703, pero la relación no es monótona: las clases de 30 a 60 imágenes promedian 0.732, más que las de 300 o más (0.690), y la correlación de Spearman entre tamaño y F1 es apenas 0.12. Los fallos se concentran en la cola de clases con menos de 30 imágenes (F1 medio 0.461) y en flores parecidas entre sí. Los pares más confundidos son *carnation* → *rose* (13 imágenes), *wild rose* → *windflower* (12), *common dandelion* → *sunflower* (12) y *common tulip* → *rose* (11): flores de forma y color similares, donde la clase predicha suele ser además la más frecuente. La Figura 8 muestra la matriz de confusión completa.

La Figura 6 muestra ejemplos reales. Los errores ilustran en qué se apoya la red: un girasol de pétalos rojos se predice como *tiger lily* y un iris barbado morado como *wild geranium*, es decir, cuando el color se aparta del típico de la clase, la red se guía por el color antes que por la forma. Varios errores tienen además confianza baja (17–42 %), mientras que los aciertos en clases características (*sunflower*, *iris*) llegan a casi 100 %.

7.5. Pesos por clase

La variante con pesos por clase cambia solo la pérdida (Sección 5.4): misma arquitectura, semilla, aumento, dropout y calendario de la tasa. No mejora a la referencia (Tabla 8). Su F1 macro baja de 0.5784 a 0.4881 y su exactitud de 64.06 % a 48.87 %; 83 de las 104 clases empeoran y solo 17 mejoran.

Los pesos sí hacen lo que se espera de ellos, pero el resultado neto es negativo. La sensibilidad (*recall*) macro queda igual, 0.56 en ambas redes, mientras que la precisión macro cae de 0.63 a 0.46: la red no reconoce mejor las flores, solo reparte sus predicciones de otra manera. Por grupos de tamaño se ve el intercambio:

- **Clases con menos de 30 imágenes (24 clases).** Su sensibilidad sube de 0.42 a 0.61 y su F1 medio de 0.461 a 0.487. Las clases con F1 = 0 bajan de cinco a dos (*bolero deep blue* y *sweet pea*), y la red llega a predecir las 104 clases (la referencia nunca predice tres). Pero las predice de más: a las 10 clases más pequeñas les asigna 112 imágenes de validación, cuando solo tienen 56 (la referencia les asignaba 25). Su precisión baja de 0.58 a 0.42, y en esas 10 clases el F1 medio incluso baja un poco (de 0.361 a 0.328), aunque con 5 imágenes de validación por clase esa diferencia está dentro del ruido.

- **Clases con 60 o más imágenes (62 clases).** Pagan el costo. En las nueve clases de 300 imágenes o más, la sensibilidad cae de 0.72 a 0.40 y el F1 de 0.690 a 0.481; *iris*, por ejemplo, pasa de reconocer 82 % de sus imágenes a 47 %. Las 44 clases de 60 a 149 imágenes, el grupo más grande, bajan de 0.530 a 0.405. Como estas clases son mayoría, dominan el promedio macro.

Las confusiones cambian de dirección. En la referencia, la flor rara se confundía con la frecuente (*carnation* → *rose*, 13 imágenes); con pesos, ocurre al revés (*rose* → *carnation*, 15). Los pares más confundidos son ahora *wild rose* → *windflower* (28), *wild geranium* → *iris* (21) e *iris* → *wild geranium* (17). La correlación entre tamaño de clase y F1 pasa de 0.12 a −0.06 (Figura 7): la dependencia del tamaño desaparece, pero porque las clases grandes bajaron, no porque las pequeñas subieran.

La red con pesos también aprende más despacio. En la época 40, su F1 de validación es 0.434, contra 0.514 de la referencia, y en el checkpoint (época 70 de 82) su F1 de entrenamiento es 0.638, contra 0.814. Por eso su brecha es menor (0.150 contra 0.235): no generaliza mejor, ajusta peor el entrenamiento.

Esta configuración se lanzó tres veces; las dos primeras corridas se interrumpieron por bloqueos de la GPU en las épocas 64 y 68, con un mejor F1 de 0.528 y 0.531. Las tres curvas coinciden hasta la época 40 (F1 de 0.436, 0.429 y 0.434). La corrida completa, que es la que se reporta, recibió su primera reducción de la tasa en la época 34, contra la 41–42 de las otras dos, y con ello quedó por debajo. La GPU no es determinista aun con semilla fija, así que una diferencia de unas 0.04 entre corridas idénticas da una idea del ruido de una sola semilla. Con cualquiera de las tres, la conclusión es la misma: los pesos por clase quedan entre 0.05 y 0.09 puntos de F1 por debajo de la referencia.

Tabla 6
Avance 4 frente al reporte final: la brecha medida con aumento subestima el sobreajuste.

Modelo	Política en Avance 4	F1 A4	Brecha exact. A4	F1 final	Brecha exact.	Brecha F1
CNN de referencia	AdamW + LR adaptable	0.5745	+0.1051	0.5784	+0.1894	+0.2354
CNN ampliada (6 conv.)	Adam, LR fijo	0.5502	+0.1687	0.5663	+0.1926	+0.2273

A4: PyTorch/DirectML; su exactitud de entrenamiento se midió durante el ciclo, con aumento y dropout activos. Final: TensorFlow/Metal, todas con AdamW + LR adaptable; brechas medidas sobre 3,712 imágenes de entrenamiento sin aumento y en modo inferencia, en la época del checkpoint.

Tabla 7
F1 por clase de la CNN de referencia: las 10 mejores y las 10 peores.

Mejores	n_{entr}	F1	Peores	n_{entr}	F1
pink-yellow dahlia	58	1.000	bolero deep blue	18	0.000
cautleya spicata	27	1.000	siam tulip	19	0.000
cape flower	57	0.971	canterbury bells	20	0.000
purple coneflower	55	0.968	pink quill	24	0.000
bishop of llandaff	58	0.941	garden phlox	24	0.000
silverbush	28	0.941	tree mallow	29	0.154
californian poppy	55	0.938	sword lily	63	0.200
geranium	63	0.919	hibiscus	134	0.243
orange dahlia	36	0.900	spring crocus	21	0.250
osteospermum	33	0.900	globe-flower	21	0.250

n_{entr}: imágenes de esa clase en entrenamiento. Desempates por tamaño de clase.

7.6. Efecto de la regularización

Para medir qué aportan las técnicas de regularización, se entrenó la misma CNN, con la misma semilla y el mismo tope de épocas, sin dropout, sin aumento de datos y con Adam en lugar de AdamW (Tabla 9 y Figura 9). Sin regularización, la red aprende más rápido al principio: llega a un F1 de validación de 0.5 en la época 25, frente a la 38 de la referencia. Pero ahí se estanca. Su mejor F1 es 0.5332, 0.045 por debajo de la referencia (0.5784), y su exactitud baja de 64.06 % a 59.64 %.

La causa es el sobreajuste. Sin regularización, el F1 de entrenamiento sube a 0.877 (0.814 con regularización) y la brecha de F1 pasa de 0.235 a 0.344. La pérdida de validación toca su mínimo en la época 25 (1.825) y después sube hasta 2.122, mientras que con regularización su mínimo es 1.464 y prácticamente no sube. El daño se concentra en las clases pequeñas: el F1 promedio de las 10 clases más pequeñas baja de 0.361 a 0.257, mientras que el de las 10 más grandes solo baja de 0.703 a 0.669. Las clases con 18–30 imágenes son las más fáciles de memorizar y, sin aumento, la red ve siempre las mismas pocas fotos.

7.7. Hiperparámetros

La Tabla 10 cambia un hiperparámetro a la vez respecto a la referencia, con el conjunto completo de entrenamiento. Ninguna de las dos variantes la mejora:

- **Tasa de aprendizaje de 3×10^{-4} (en vez de 10^{-3}): F1 0.4605.** Es la peor de las CNN, pero no por sobreajuste: su brecha de F1 es solo 0.094 porque la red tampoco aprende bien el entrenamiento (F1 de entrenamiento 0.554, contra 0.814 de la referencia). La reducción automática de la tasa ocurre cuando la pérdida de validación deja de mejorar dos épocas; al partir de una tasa ya baja, en pocas reducciones llega al mínimo de 10^{-5} y el aprendizaje prácticamente se detiene. En la época del checkpoint (98) la tasa ya estaba en ese mínimo. Es infraajuste causado por el calendario de la tasa, no por la capacidad de la red.
- **Dropout de 0.3 (en vez de 0.5): F1 0.5596.** Con menos dropout, el F1 de entrenamiento es prácticamente igual (0.816 contra 0.814), pero el de validación baja 0.019 y la brecha sube de 0.235 a 0.256. Es el

Tabla 8
Pérdida ponderada por clase frente a la pérdida sin ponderar.

Entrenamiento	Exact. (%)	F1 10 menores	F1 10 mayores	Clases F1 = 0	F1 macro
CNN de referencia	64.06	0.3607	0.7034	5	**0.5784**
Pesos por clase	48.87	0.3281	0.5050	2	0.4881

F1 10 menores/mayores: F1 promedio de las 10 clases con menos (18–19) y más (460–782) imágenes de entrenamiento. Pesos $w_c = N/(K\,n_c)$: van de 0.16 (iris) a 6.81 (las clases de 18 imágenes).

Tabla 9
La misma CNN con y sin regularización (semilla 0, mismas épocas máximas).

Variante	Dropout	Aumento	Pesos	Época	Exact. (%)	F1 entr.	Brecha F1	F1 macro
CNN de referencia	0.5	sí	WD 0.01	91/103	64.06	0.8138	+0.2354	**0.5784**
Sin regularización	0	no	–	34/46	59.64	0.8767	+0.3435	0.5332

Pesos: WD = weight decay desacoplado de AdamW; – = Adam sin decaimiento. Ambas comparten arquitectura, tasa de aprendizaje inicial, reducción de LR en meseta, paciencia de 12 evaluaciones y tope de 150 épocas.

Tabla 10
Efecto de un hiperparámetro a la vez, con el conjunto completo.

Configuración	LR	Dropout	Resolución	Época	Exact. (%)	Brecha F1	Tiempo (min)	F1 macro
CNN de referencia	0.001	0.5	112	91/103	64.06	+0.2354	19.7	**0.5784**
LR 3×10^{-4}	0.0003	0.5	112	98/110	54.18	+0.0936	22.5	0.4605
Dropout 0.3	0.001	0.3	112	61/73	61.96	+0.2561	15.0	0.5596

Cada fila cambia un solo valor respecto a la referencia (LR 10^{-3}, dropout 0.5, 112×112).

mismo patrón que sin regularización, en menor grado: menos regularización, más memorización. De nuevo, las clases pequeñas son las que más pierden (0.286 contra 0.361).

Con una sola semilla, la diferencia de 0.019 del dropout es moderada; la de la tasa de aprendizaje (0.118) es clara.

7.8. Reducción de datos con Distribution Matching

Como experimento independiente de los anteriores, se evaluó si un conjunto pequeño de imágenes sintéticas generado con Distribution Matching (DM) (Zhao & Bilen, 2023) conserva más información que el mismo número de imágenes reales elegidas al azar (Tabla 11). Con una imagen por clase (IPC 1, 104 imágenes), DM supera a la selección aleatoria (F1 0.067 frente a 0.051). Con diez por clase (IPC 10, 1,040 imágenes) ocurre lo contrario: las imágenes reales dan 0.258 y las sintéticas 0.204, con más variación entre semillas. La destilación ayuda solo cuando hay muy pocas imágenes, y su costo (16 y 25 minutos de generación) se suma al del entrenamiento. Ninguna de estas imágenes se usó en los demás experimentos; todos entrenan con las 12,753 imágenes reales.

8. Análisis

8.1. Por qué la CNN supera a la MLP

La diferencia entre la MLP (F1 0.018) y la CNN de referencia (F1 0.578) no es de grado sino de tipo: la MLP no logra ajustar ni siquiera el entrenamiento (F1 de entrenamiento 0.019), mientras que la CNN sí lo ajusta y luego generaliza parcialmente. La causa está en cómo cada red trata la imagen.

- **La MLP no comparte pesos.** Aplana la imagen en 37,632 valores y conecta cada uno con cada neurona oculta: el 99.7 % de sus 9.66 millones de parámetros está en esa primera capa. Un pétalo en la esquina superior y el mismo pétalo en el centro activan pesos distintos, así que la red tendría que aprender cada patrón por separado en cada posición. Con 122 imágenes por clase en promedio, no hay datos suficientes para eso.
- **La CNN codifica supuestos correctos sobre imágenes.** Sus filtros de 3×3 miran vecindarios locales y se aplican en toda la imagen (pesos compartidos), las capas sucesivas combinan bordes en texturas y texturas en partes, y el *pooling* global hace que la predicción dependa de qué hay en la imagen y no de dónde está. Con 20 veces menos parámetros (480,936) aprovecha mucho mejor los mismos datos.
- **La MLP se refugia en las clases grandes.** Solo predice 11 clases y su F1 por clase sí depende fuertemente del tamaño de la clase (Spearman 0.51, frente a 0.12 en la CNN): sin poder distinguir flores, lo mejor que encuentra es favorecer las clases más frecuentes. Además es inestable: con la tasa de 10^{-3} de la CNN colapsa a una sola clase, por lo que necesitó 10^{-4}.

La comparación no aísla por completo el efecto de las convoluciones: las dos redes difieren también en número de parámetros y la MLP usa una tasa de aprendizaje diez veces menor. Aun así, una diferencia de 0.56 puntos de F1 macro con la misma política de entrenamiento, los mismos datos y el mismo aumento no se explica por la tasa: con la tasa de la CNN, la MLP es todavía peor.

Los regularizadores no son el problema de la MLP: su curva con aumento y dropout (gris en la Figura 5) es todavía peor que la limpia, y su brecha es nula. Regularizar más una red que infraajusta no la ayudaría.

8.2. Por qué la CNN más profunda empeoró

Agregar dos convoluciones (de 480,936 a 1,218,600 parámetros) bajó el F1 de 0.578 a 0.566. Con una sola semilla, una diferencia de 0.012 es pequeña, pero coincide

Tabla 11
Selección aleatoria frente a destilación con Distribution Matching (DM).

IPC	Imágenes	Conjunto	Exact. (%)	F1 macro	Destilación (min)
1	104	Sintéticas (DM)	9.85	0.0672 ± 0.0052	16
1	104	Reales aleatorias	5.75	0.0514 ± 0.0029	–
10	1,040	Sintéticas (DM)	20.55	0.2044 ± 0.0235	25
10	1,040	Reales aleatorias	25.86	0.2575 ± 0.0082	–

Promedio ± desviación estándar de tres semillas de entrenamiento por condición. Misma CNN, Adam 10^{-3}, 112×112. Datos: `reports/resultados.csv`.

con el Avance 4 (0.574 contra 0.550) y las curvas explican por qué la red más grande no mejora:

- **Más capacidad sin más datos.** La red ampliada ajusta el entrenamiento mucho más rápido: en la época 41 su F1 de entrenamiento es 0.794, contra 0.638 de la referencia, pero su F1 de validación se estanca en 0.564. La capacidad extra se usa para memorizar detalles del entrenamiento, sobre todo en las clases con 18–30 imágenes, no para aprender rasgos que generalicen.
- **El sobreajuste aparece antes.** Su pérdida de validación toca su mínimo en la época 34 (frente a la 54 de la referencia) y después sube, y tiene seis clases con F1 = 0 en vez de cinco.
- **La regularización estaba calibrada para la CNN de referencia.** Ambas usan dropout 0.5 y decaimiento de pesos de 0.01, valores elegidos para la CNN de cuatro convoluciones (480,936 parámetros). Para la CNN ampliada, con 2.5 veces más parámetros, esa misma regularización es relativamente más débil.
- **Más profundidad no agrega información a 112×112.** Las dos capas nuevas operan sobre mapas ya reducidos; a esa resolución, los detalles finos que distinguen flores parecidas (*carnation* contra *rose*) ya se perdieron en la entrada, y ninguna capa extra los recupera.

En resumen, el techo de cerca de 64 % de exactitud refleja dos límites que actúan juntos. Uno es de capacidad: una CNN pequeña entrenada desde cero a 112×112 no aprende rasgos suficientemente finos para separar flores parecidas. El otro es de datos: con pocas imágenes por clase, agregar capas no compra rasgos mejores, solo memorización. Por eso hacer la red más grande no ayudó, mientras que el aumento de datos sí, y por eso el paso con más potencial es aportar capacidad ya entrenada con otros datos (transferencia de aprendizaje).

8.3. Qué aporta la regularización

Los tres experimentos de regularización apuntan en la misma dirección: quitar regularización (Sección 7.6) o reducirla (dropout 0.3) sube el F1 de entrenamiento o lo deja igual, pero baja el de validación y abre la brecha. Con 12,753 imágenes y 480,936 parámetros, la CNN tiene capacidad de sobra para memorizar el entrenamiento; la regularización es la que le permite generalizar. Su efecto conjunto vale 0.045 puntos de F1 macro.

La regularización no elimina el sobreajuste: la referencia conserva una brecha de 0.235. Las curvas muestran que la brecha se estabiliza alrededor de la época 60, justo cuando la reducción automática de la tasa lleva el aprendizaje casi a cero. A partir de ahí la red deja de cambiar, en vez de seguir memorizando. Esto también explica por qué la referencia toma su mejor checkpoint tan tarde (época 91): son ajustes finos con una tasa de 10^{-5}.

8.4. Sensibilidad a los hiperparámetros

La tasa de aprendizaje es, de lejos, el hiperparámetro más sensible: bajarla a 3×10^{-4} cuesta 0.118 de F1, más que quitar toda la regularización. La causa es la interacción con la reducción en meseta: una tasa inicial baja hace que el calendario la lleve al mínimo antes de que la red aprenda lo suficiente. Con este calendario, 10^{-3} es la elección correcta. El dropout es menos sensible: entre 0.3 y 0.5 la diferencia es de 0.019, a favor de 0.5.

8.5. Por qué los pesos por clase no ayudaron

Ponderar la pérdida con $w_c = N/(K\,n_c)$ equivale a entrenar como si todas las clases fueran igual de frecuentes. Pero validación conserva exactamente el desbalance de entrenamiento. Ante una imagen ambigua entre *iris* (782 imágenes) y una clase de 20, lo más probable es que sea *iris*; la red sin pesos aprende esa preferencia y la red con pesos la pierde. Por eso la sensibilidad macro no cambia (0.56) y la precisión baja (de 0.63 a 0.46): la red no gana capacidad para distinguir flores, solo desplaza sus predicciones hacia las clases raras, que reciben el doble de predicciones de las que les corresponden.

El costo para el F1 macro es asimétrico. Las 24 clases con menos de 30 imágenes ganan poco (0.026 de F1 medio), porque casi todas las imágenes que reciben de más son errores. Las 62 clases con 60 o más imágenes pierden mucho (más de 0.1), porque sus imágenes se van a las clases raras. Como el F1 macro promedia por clase y las clases medianas y grandes son mayoría, el saldo es negativo.

A esto se suma que la red aprende más despacio. Con pesos de 0.16 a 6.8, las clases grandes aportan poco a la pérdida y cada lote depende mucho de unas cuantas imágenes raras con peso alto, de modo que los gradientes son

más ruidosos. La pérdida de validación, que no lleva pesos, queda más alta y estancada (su mínimo es 1.93, contra 1.46 en la referencia), y el calendario en meseta, que la vigila, reduce la tasa antes. Las tres corridas lo confirman: llegan a la época 40 por debajo de la referencia, y la que redujo la tasa antes terminó más abajo.

Los resultados sugieren que el problema de las clases raras no es que la red las ignore por ser raras, sino que tiene muy pocas fotos para aprenderlas. Las alternativas más prometedoras, que no se probaron, atacan una cosa o la otra: pesos más suaves (por ejemplo, $w_c \propto 1/\sqrt{n_c}$), corregir los umbrales de decisión después de entrenar sin pesos (para no perder la preferencia por las clases frecuentes) o, sobre todo, más información por imagen mediante transferencia de aprendizaje.

8.6. Limitaciones

Cada configuración se entrenó con una sola semilla, por lo que diferencias de menos de unas centésimas de F1 no deben tomarse como concluyentes. La única estimación del ruido viene de las tres corridas de pesos por clase: con la misma semilla y configuración, su mejor F1 varió en unas 0.04, porque la GPU no es determinista y el calendario en meseta amplifica pequeñas diferencias. Por eso la diferencia entre la referencia y la CNN ampliada (0.012) y la del dropout (0.019) no son concluyentes. La de la regularización (0.045) está en el límite del ruido por sí sola, aunque la respaldan la brecha y las curvas de pérdida, que se comportan como se espera del sobreajuste. Las de la tasa de aprendizaje (0.118), los pesos por clase (0.090) y la MLP (0.56) son claramente mayores. La validación se usó para elegir el checkpoint de cada corrida, lo que sesga sus métricas ligeramente hacia arriba, y no se cuenta con una medida sobre datos nunca vistos porque no se enviaron predicciones de prueba a Kaggle. La corrida de la CNN ampliada se interrumpió en la época 50. Todas las redes se entrenaron desde cero a 112×112; no se evaluó transferencia de aprendizaje desde modelos preentrenados.

9. Conclusiones

El mejor modelo de este trabajo es la CNN de referencia: cuatro convoluciones, 480,936 parámetros, dropout de 0.5, aumento de datos, AdamW y reducción de la tasa en meseta. En validación alcanza un F1 macro de 0.5784 y una exactitud de 64.06 %. Ninguno de los seis cambios evaluados, cada uno aislado respecto a ella, la superó.

Las preguntas que planteaba el trabajo tienen respuestas claras:

- **¿Ayuda extraer patrones espaciales?** Sí, y de forma decisiva. La MLP, con 20 veces más parámetros, no logra ajustar ni el entrenamiento (F1 de 0.018). Compartir filtros locales en toda la imagen es lo que hace aprendible el problema con unas cien imágenes por clase.
- **¿Ayuda una red más profunda?** No. La CNN ampliada memoriza el entrenamiento más rápido, pero su validación se estanca en el mismo nivel (F1 de 0.566). Con una sola semilla, su diferencia con la referencia está dentro del ruido; lo que sí muestra es que, con estos datos, agregar capas no basta para subir el techo.
- **¿Ayuda la regularización?** Sí. Sin dropout, aumento ni decaimiento de pesos, la brecha de F1 sube de 0.235 a 0.344 y el F1 de validación baja 0.045, con la mayor pérdida en las clases pequeñas. Reducir el dropout a 0.3 va en la misma dirección.
- **¿Ayuda compensar el desbalance con pesos por clase?** No. Sube la sensibilidad de las clases raras, pero a costa de predecirlas de más y de perder las clases medianas y grandes, que son mayoría; el F1 macro baja a 0.488.
- **¿Qué tan sensibles son los hiperparámetros?** La tasa de aprendizaje es el más sensible: con 3×10^{-4}, el calendario en meseta la lleva al mínimo antes de que la red aprenda, y el F1 baja a 0.461.

En conjunto, los experimentos muestran un techo cercano a 64 % de exactitud con dos causas que actúan juntas: la capacidad limitada de una CNN pequeña entrenada desde cero y la falta de datos por clase, que impide que más capas se traduzcan en rasgos útiles. Lo que ataca la falta de datos, como el aumento, ayuda; lo que agrega capas sin más datos o solo redistribuye las predicciones, no. El análisis de errores lo confirma: los fallos se concentran en flores parecidas entre sí (*carnation* y *rose*, *wild rose* y *windflower*) y en las 24 clases con menos de 30 imágenes, donde a 112×112 los detalles que las distinguen se pierden.

Frente al Avance 4, este reporte corrige la forma de medir el sobreajuste. Al evaluar el entrenamiento sin aumento ni dropout, la brecha real de la referencia resulta casi el doble de la reportada antes. Además, todo el proceso es reproducible: el notebook reconstruye la tabla de resultados, las tablas y las figuras a partir de los historiales versionados de cada corrida.

9.1. Trabajo futuro

El paso con más potencial es la transferencia de aprendizaje: una red preentrenada en ImageNet (por ejemplo, EfficientNetB0 o ResNet50) a 224×224 aporta rasgos aprendidos de millones de imágenes, que es justo lo que falta aquí, y la resolución mayor conserva los detalles que separan flores parecidas. Para el desbalance, conviene probar pesos más suaves o corregir los umbrales de decisión después de entrenar, en lugar de pesos inversamente proporcionales al tamaño. Por último, repetir cada configuración con varias semillas permitiría decidir las diferencias pequeñas que hoy quedan dentro del ruido, como las de la CNN ampliada y el dropout.

10. Conclusión individual (Angel Luna)

Este proyecto me permitió comprobar, con evidencia experimental y no solo con intuición teórica, qué factores determinan realmente el desempeño de una red neuronal en

un problema de clasificación de imágenes con pocos datos por clase. Con una CNN de referencia de cuatro convoluciones y 480,936 parámetros se obtuvo un F1 macro de 0.5784 y una exactitud de 64.06, % en validación. Ninguno de los seis cambios evaluados, cada uno aislado respecto a ella, logró superarla.

El resultado que considero más instructivo es la comparación entre la MLP y la CNN. Con veinte veces más parámetros, la MLP alcanzó un F1 de apenas 0.018 y no pudo ajustar ni el entrenamiento. Se sigue que lo decisivo no es el número de parámetros, sino que la arquitectura incorpore el supuesto correcto sobre los datos: los filtros locales con pesos compartidos hacen aprendible el problema con alrededor de cien imágenes por clase. Esto me dejó claro que la capacidad de un modelo debe entenderse junto con su sesgo inductivo y no de forma aislada.

También aprendí que más capacidad no implica mejor generalización. La CNN ampliada memorizó el entrenamiento más rápido, pero su validación se estancó en el mismo nivel (F1 de 0.566). Del mismo modo, los pesos por clase, que en principio parecen una solución natural al desbalance, redujeron el F1 macro a 0.488: la sensibilidad macro no cambió y la precisión cayó, es decir, la red solo redistribuyó sus predicciones en lugar de distinguir mejor las flores. En cambio, la regularización sí aportó (el F1 de validación bajó 0.045 al retirarla y la brecha de F1 subió de 0.235 a 0.344), y la tasa de aprendizaje resultó ser el hiperparámetro más sensible por su interacción con la reducción en meseta.

Un aprendizaje metodológico importante fue corregir la forma de medir el sobreajuste. Al evaluar el entrenamiento sin aumento de datos y sin dropout, la brecha real resultó casi el doble de la reportada en el avance anterior. Aprendí que una métrica solo es comparable cuando se mide bajo las mismas condiciones, y que una conclusión puede cambiar por completo según cómo se calcule.

Reconozco también las limitaciones del trabajo. Cada configuración se entrenó con una sola semilla y las corridas repetidas de los pesos por clase mostraron una variación de aproximadamente 0.04 en F1, por lo que diferencias pequeñas, como la de la CNN ampliada o la del dropout, no son concluyentes. Además, la validación se usó para elegir el checkpoint y no se evaluó sobre datos nunca vistos. Con estas salvedades, las diferencias grandes (MLP, tasa de aprendizaje y pesos por clase) sí son sólidas.

Finalmente, los resultados señalan un techo cercano a 64, % de exactitud con dos causas que actúan juntas: la capacidad limitada de una CNN pequeña entrenada desde cero a 112×112 y la escasez de datos por clase. Por ello, el siguiente paso natural es la transferencia de aprendizaje desde un modelo preentrenado en ImageNet, junto con repetir los experimentos con varias semillas. Más allá de la cifra final, el proyecto me deja una forma de trabajo que considero valiosa: cambiar un solo factor a la vez, medir con cuidado y no atribuir a una mejora lo que podría ser ruido.

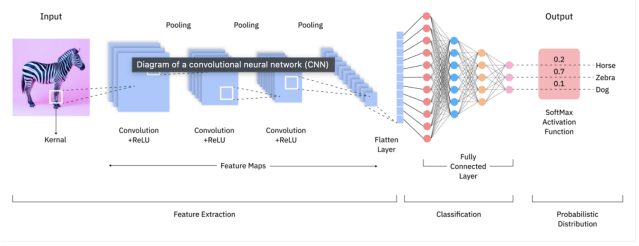


Figura 2: Esquema de una red convolucional: las convoluciones extraen características de la imagen y las capas densas las usan para clasificar (Clark, 2025).

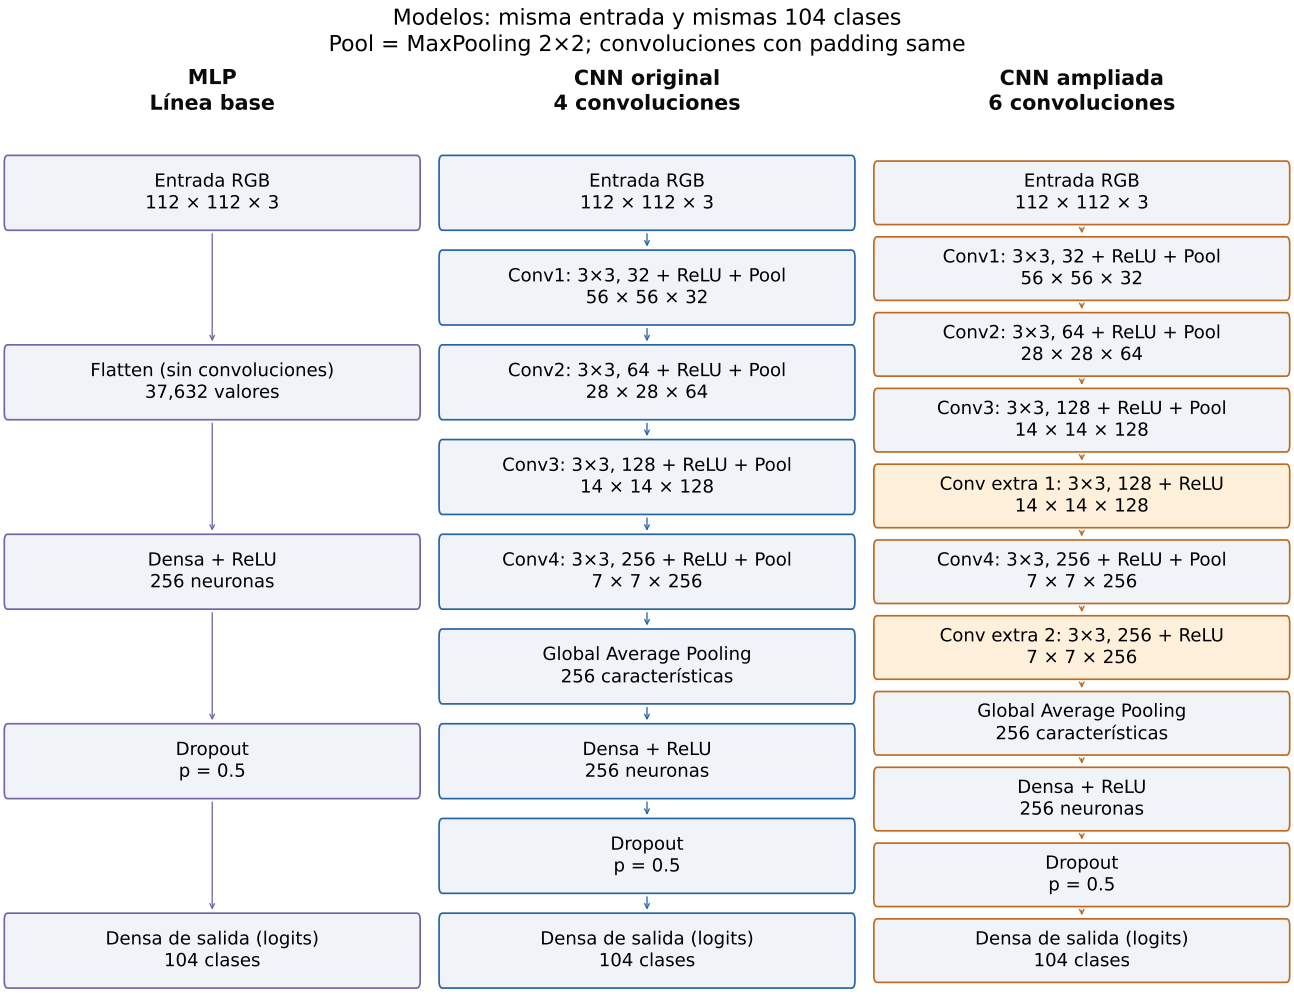


Figura 3: Representación de la red totalmente conectada de referencia, la CNN original y la CNN con dos convoluciones adicionales. Las dimensiones corresponden a las salidas de cada etapa; las capas adicionales se destacan en naranja. La variante regularizada conserva la arquitectura de la CNN original.

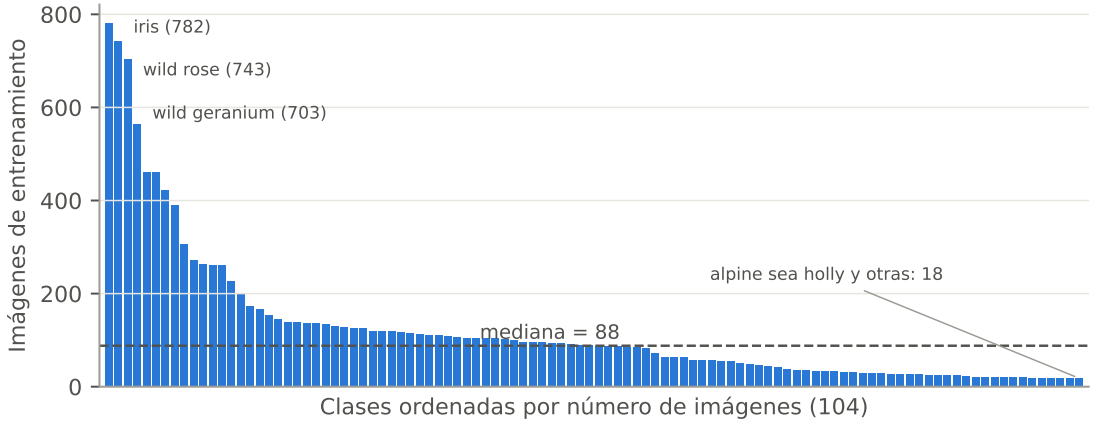


Figura 4: Imágenes de entrenamiento por clase, ordenadas de mayor a menor. La línea punteada marca la mediana (88).

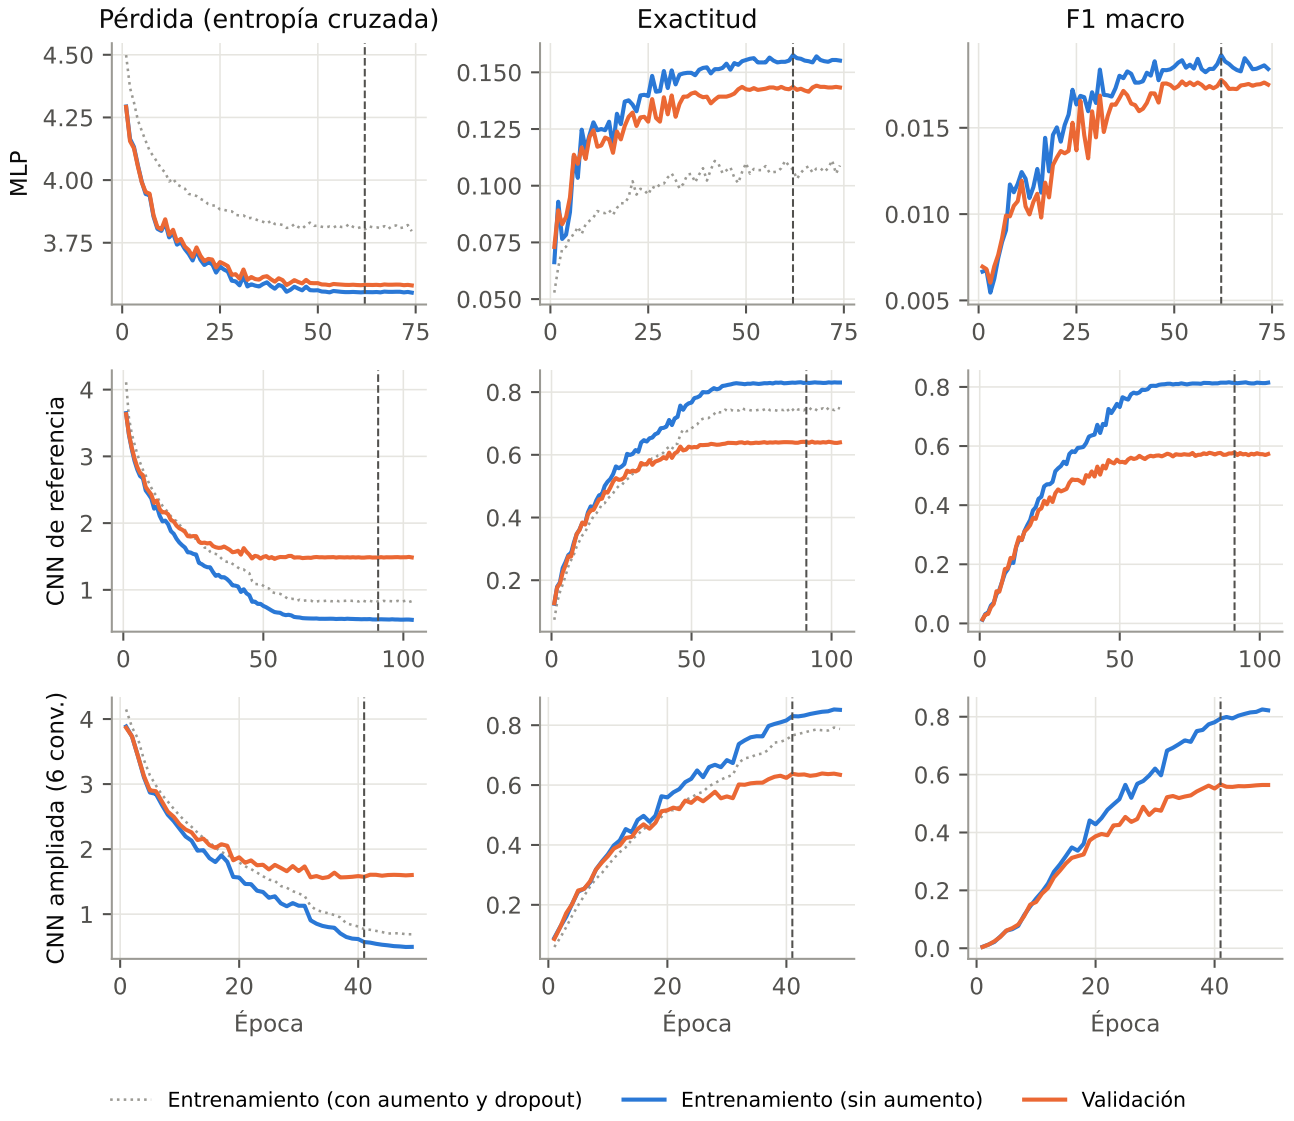


Figura 5: Curvas de entrenamiento y validación por época. Azul: 3,712 imágenes fijas de entrenamiento sin aumento, en modo inferencia. Naranja: validación. Gris punteado: la métrica que reporta el ciclo de entrenamiento, con aumento y dropout activos (no existe para el F1). La línea vertical marca el checkpoint elegido. Las escalas verticales de la MLP son distintas.

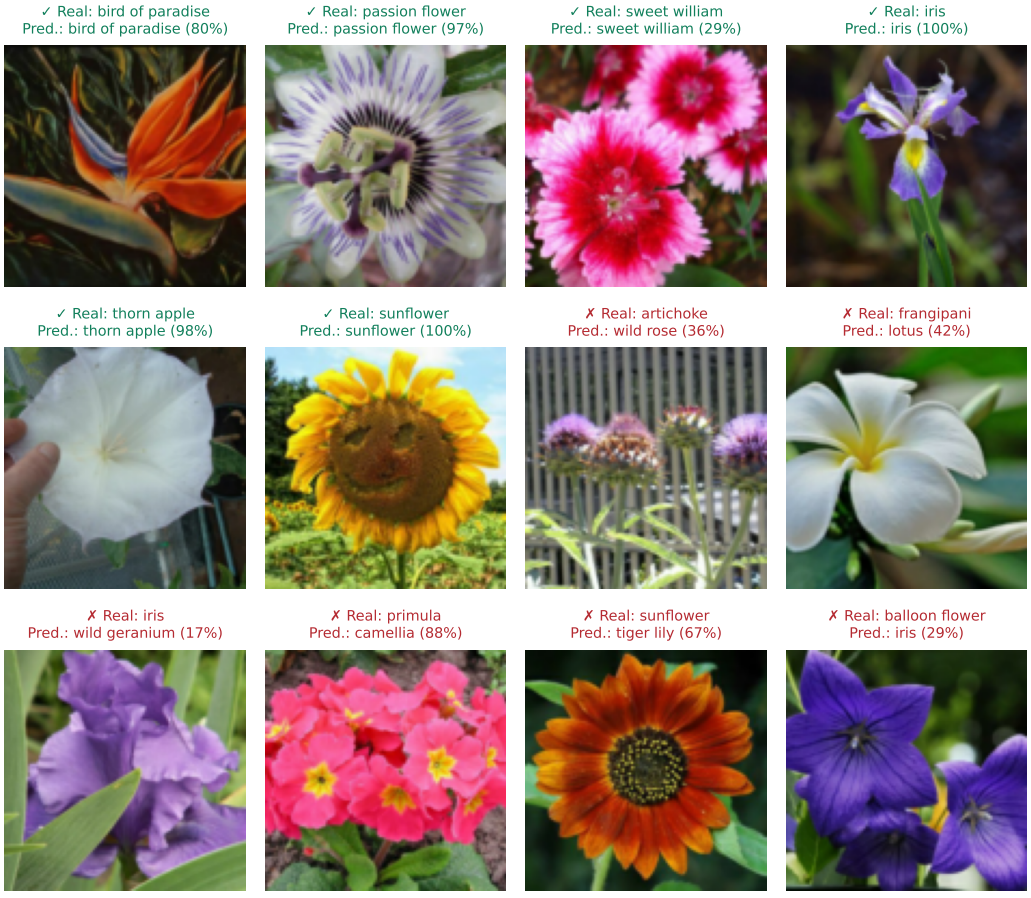


Figura 6: Seis aciertos (verde, ✓) y seis errores (rojo, ×) de la CNN de referencia en validación, elegidos con semilla fija; entre paréntesis, la probabilidad softmax de la clase predicha. La proporción es ilustrativa: la red acierta en 2,378 de 3,712 imágenes.

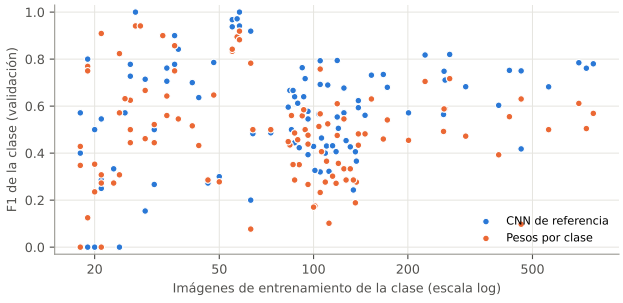


Figura 7: F1 de validación de cada clase frente a su número de imágenes de entrenamiento (escala logarítmica).

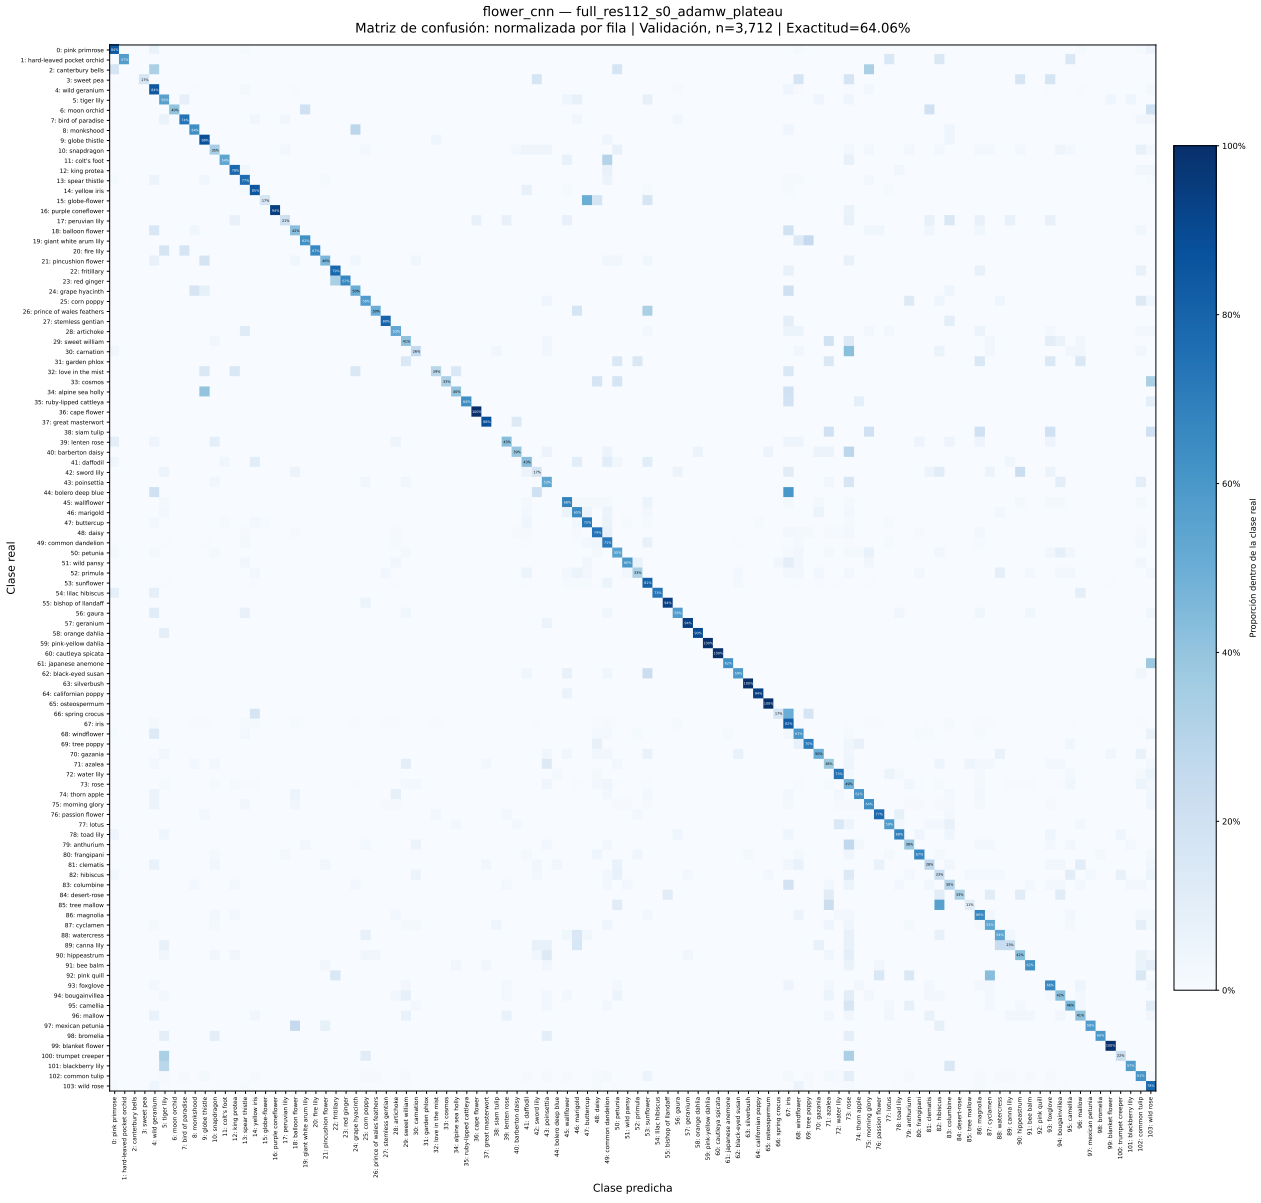


Figura 8: Matriz de confusión normalizada por fila de la CNN de referencia en validación (104 clases).

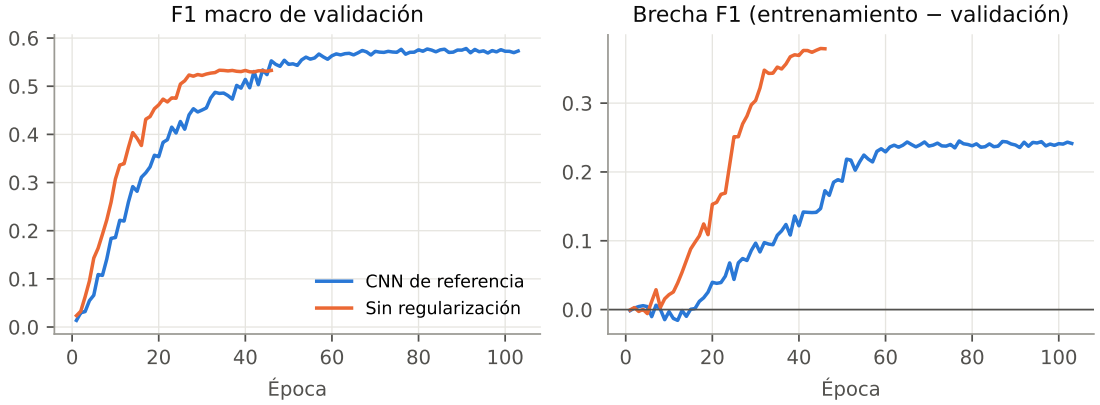


Figura 9: F1 macro de validación y brecha de F1 por época, con y sin regularización (misma semilla, arquitectura y tope de épocas).

Referencias

Biewald, L. (2020). *Experiment Tracking with Weights and Biases*. Consultado el 22 de octubre de 2026, desde https://wandb.ai/site

Clark, B. (2025). *What Is Image Classification?* IBM. Consultado el 28 de septiembre de 2026, desde https://www.ibm.com/think/topics/image-classification

Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., & Fei-Fei, L. (2009). ImageNet: A Large-Scale Hierarchical Image Database. *2009 IEEE Conference on Computer Vision and Pattern Recognition*, 248-255. https://doi.org/10.1109/CVPR.2009.5206848

He, H., & Garcia, E. A. (2009). Learning from Imbalanced Data. *IEEE Transactions on Knowledge and Data Engineering*, *21*(9), 1263-1284. https://doi.org/10.1109/TKDE.2008.239

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770-778. https://doi.org/10.1109/CVPR.2016.90

iNaturalist. (2026). *iNaturalist: A Community for Naturalists*. Consultado el 28 de septiembre de 2026, desde https://www.inaturalist.org

Kaggle. (s.f.). *Petals to the Metal - Flower Classification on TPU*. Consultado el 28 de septiembre de 2026, desde https://www.kaggle.com/competitions/tpu-getting-started/overview

Lin, M., Chen, Q., & Yan, S. (2014). Network In Network. *2nd International Conference on Learning Representations (ICLR)*. https://arxiv.org/abs/1312.4400

Loshchilov, I., & Hutter, F. (2019). Decoupled Weight Decay Regularization. *International Conference on Learning Representations (ICLR)*. Consultado el 22 de octubre de 2026, desde https://openreview.net/forum?id=Bkg6RiCqY7

Nilsback, M.-E., & Zisserman, A. (2008). Automated Flower Classification over a Large Number of Classes. *2008 Sixth Indian Conference on Computer Vision, Graphics & Image Processing*, 722-729. https://doi.org/10.1109/ICVGIP.2008.47

Secretaría de Agricultura y Desarrollo Rural. (2022, octubre). *Floricultura mexicana: aporte en la celebración del Día de Muertos*. Consultado el 22 de octubre de 2026, desde https://www.gob.mx/cms/uploads/attachment/file/769150/BOLETIN_FLORICULTURA_DI_A_DE_MUERTOS_22.pdf

Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *Journal of Machine Learning Research*, *15*(56), 1929-1958. Consultado el 22 de octubre de 2026, desde https://jmlr.org/papers/v15/srivastava14a.html

Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. *Proceedings of the 36th International Conference on Machine Learning*, *97*, 6105-6114. Consultado el 22 de octubre de 2026, desde https://proceedings.mlr.press/v97/tan19a.html

Zhao, B., & Bilen, H. (2023). Dataset Condensation with Distribution Matching. *2023 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 6503-6512. https://doi.org/10.1109/WACV56688.2023.00645